

Manual Book Skripsi — Panduan Membaca BAB III & BAB IV

Pendamping naskah *Analisis Performa Post-Training Quantization (PTQ) pada Small Language Model untuk Implementasi Edge Computing Berbasis Android*

Ai Sha

Mei 2026

Contents

Pengantar	3
Bagian 1: Glosarium Istilah Teknis	4
1.1 Istilah Tingkat Sistem	4
1.1.1 SLM (<i>Small Language Model</i>)	4
1.1.2 PTQ (<i>Post-Training Quantization</i>)	4
1.1.3 GGUF	4
1.1.4 <i>k-quants</i>	4
1.1.5 F16 (FP16)	4
1.1.6 <i>Edge Computing / Edge AI / Mobile Edge AI</i>	4
1.1.7 <i>Host-to-Target Deployment</i>	5
1.1.8 OOM (<i>Out-of-Memory</i>) dan <i>Force Close</i>	5
1.1.9 <i>Thermal Throttling</i>	5
1.2 Istilah Performa Perangkat Keras (<i>Hardware</i>)	5
1.2.1 <i>Peak RAM (MB)</i>	5
1.2.2 <i>CPU Peak (%)</i>	5
1.2.3 <i>Prompt Speed (Prompt TPS, t/s)</i>	5
1.2.4 <i>Generation Speed (Gen TPS, t/s)</i>	6
1.2.5 Total Waktu Eksekusi (s)	6
1.2.6 <i>Token</i>	6
1.3 Istilah Performa Kognitif (<i>Software / AI</i>)	6
1.3.1 <i>Perplexity (PPL)</i>	6
1.3.2 MMLU (<i>Massive Multitask Language Understanding</i>)	6
1.3.3 GSM8K (<i>Grade School Math 8K</i>)	6
1.3.4 HumanEval (<i>Code Generation Benchmark</i>)	7
1.3.5 MT-Bench TTR (<i>Type-Token Ratio</i>)	7
1.3.6 Retensi Kepintaran / Retensi Akurasi (%)	7
1.3.7 Delta (Δ) Akurasi	7
1.3.8 <i>Compound Score</i>	7
1.4 Istilah Statistik (BAB 4.4.6)	8
1.4.1 N (Jumlah Replikasi)	8
1.4.2 Rerata (<i>mean</i>) dan Simpangan Baku (<i>standard deviation, std</i>)	8

1.4.3 <i>t</i> -test / Welch's <i>t</i> -test	8
1.4.4 ANOVA (<i>Analysis of Variance</i>)	8
1.4.5 <i>p</i> -value (Nilai <i>p</i>)	9
1.4.6 Notasi pada Tabel IV.8 dan IV.9	9
Bagian 2: Panduan Membaca Tabel BAB III	10
2.1 Tabel III.0 – Pemetaan Langkah MobileAIBench ke Tahap Penelitian	10
2.2 Tabel III.1 – Spesifikasi Perangkat Keras	10
2.3 Tabel III.2 – Spesifikasi Perangkat Lunak	10
Bagian 3: Panduan Membaca Tabel BAB IV	11
3.1 Tabel IV.1 – Reduksi Ukuran Berkas Model	11
3.2 Tabel IV.2 – Performa Inferensi (Tabel Terpadat)	11
3.3 Tabel IV.3 – <i>Perplexity</i> (PPL)	12
3.4 Tabel IV.4 – Akurasi LFM 2.5	12
3.5 Tabel IV.5 – Akurasi Qwen 3.5	12
3.6 Tabel IV.6 – <i>Delta</i> Akurasi LFM 2.5	12
3.7 Tabel IV.7 – Matriks Rekomendasi LFM 2.5	13
3.8 Tabel IV.6-B – <i>Delta</i> Akurasi Qwen 3.5	14
3.9 Tabel IV.7-B – Matriks Rekomendasi Qwen 3.5	14
3.10 Tabel IV.8 – Uji Statistik LFM 2.5	14
3.11 Tabel IV.9 – Uji Statistik Qwen 3.5	15
Bagian 4: Ringkasan Pengambilan Keputusan	16
Bagian 5: Penjelasan Notasi dan Simbol	17
Bagian 6: Catatan Penutup	18

Pengantar

Manual book ini dibuat sebagai pendamping naskah skripsi untuk memudahkan pembaca memahami **istilah teknis**, **rumus**, dan **tabel** yang muncul pada BAB III (Metodologi Penelitian) dan BAB IV (Hasil Penelitian dan Pembahasan). Setiap bagian disusun dengan format:

1. **Definisi singkat** dalam Bahasa Indonesia.
2. **Analogi atau penjelasan sehari-hari** agar konsep mudah dibayangkan.
3. **Contoh angka** yang diambil langsung dari tabel di skripsi.
4. **Cara membaca** tabel atau formula, langkah per langkah.

Manual ini tidak menambah atau mengubah data eksperimen. Tujuannya semata menyediakan glosarium dan panduan bagi pembaca awam (termasuk penulis sendiri) ketika perlu kembali ke naskah utama untuk meninjau hasil penelitian.

Bagian 1: Glosarium Istilah Teknis

1.1 Istilah Tingkat Sistem

1.1.1 SLM (*Small Language Model*)

Model bahasa berukuran 1–3 miliar parameter. Dibanding LLM (*Large Language Model*) yang punya ratusan miliar parameter, SLM cukup ringan untuk dijalankan di perangkat seluler. Pada skripsi ini diuji dua SLM, yaitu **LFM 2.5** (1,2 miliar parameter) dan **Qwen 3.5** (2 miliar parameter).

1.1.2 PTQ (*Post-Training Quantization*)

Teknik kompresi model setelah model selesai dilatih. PTQ menurunkan presisi angka di bobot model (misalnya dari 16-bit menjadi 4-bit) supaya ukuran berkas mengecil dan inferensi lebih cepat, dengan trade-off penurunan akurasi yang relatif kecil.

1.1.3 GGUF

Format berkas biner yang dipakai llama.cpp untuk menyimpan model terkuantisasi. Bobot disimpan sudah dalam bentuk presisi rendah (F16/Q5/Q4/Q3) sehingga bisa langsung dimuat ke RAM tanpa perlu konversi tambahan saat *runtime*.

1.1.4 *k-quants*

Strategi kuantisasi presisi campuran yang dipakai pada GGUF. Bobot “penting” (misalnya pada lapisan atensi atau lapisan akhir) diberi presisi lebih tinggi, sedangkan bobot “biasa” dikompresi lebih agresif. Pada skripsi ini diuji tiga varian:

Q5_K_M – presisi 5-bit, kualitas paling dekat dengan F16.

Q4_K_M – presisi 4-bit, *sweet spot* antara ukuran dan akurasi.

Q3_K_M – presisi 3-bit, paling kecil tetapi paling banyak kehilangan akurasi.

1.1.5 F16 (FP16)

Format *floating-point* 16-bit. Pada skripsi ini F16 dipakai sebagai **baseline** (variabel kontrol) karena dianggap mendekati presisi penuh tanpa kompresi.

1.1.6 *Edge Computing / Edge AI / Mobile Edge AI*

Paradigma komputasi yang menjalankan inferensi AI **di perangkat pengguna** (misalnya *smartphone*) alih-alih di server *cloud*. Tujuan utamanya adalah privasi data, latensi rendah, dan kemampuan operasi *offline*.

1.1.7 Host-to-Target Deployment

Pola kerja dua mesin: bobot model disiapkan di **host** ber-GPU (PC NVIDIA RTX 3060), lalu berkas .gguf hasilnya dipindahkan ke **target** (Tecno Pova 5) untuk dieksekusi pada lingkungan akhir.

1.1.8 OOM (Out-of-Memory) dan Force Close

OOM Killer adalah mekanisme Android yang menghentikan paksa aplikasi saat RAM hampir habis, biasanya tampak sebagai *Force Close* di layar pengguna. Salah satu alasan utama mengapa SLM perlu dikuantisasi adalah mencegah pemicuan *OOM Killer* ini.

1.1.9 Thermal Throttling

Penurunan otomatis frekuensi CPU/GPU ketika suhu chip melewati ambang aman. Pada *smartphone* yang inferensi LLM-nya berlangsung beberapa menit, *thermal throttling* dapat membuat *throughput* turun pelan-pelan walau model tidak berubah.

1.2 Istilah Performa Perangkat Keras (Hardware)

1.2.1 Peak RAM (MB)

Jumlah memori RAM **maksimum** yang dipakai proses inferensi selama satu sesi. Diukur dari VmRSS di /proc/<pid>/status setiap 0,5 detik. Semakin kecil semakin baik karena memberi ruang lebih besar bagi OS dan aplikasi lain.

Contoh dari Tabel IV.2: LFM 2.5 F16 menyerap 2.303,47 MB, sedangkan LFM 2.5 Q3_K_M hanya 911,97 MB – artinya kuantisasi menghemat hampir 1,4 GB RAM.

1.2.2 CPU Peak (%)

Beban CPU **maksimum** yang dicapai selama inferensi, diukur via metrik %CPU di ps. Karena penelitian ini mengalokasikan **enam thread**, skala teoritisnya **0–600%**. Nilai 300% berarti tiga *thread* penuh terpakai; 600% berarti semua *thread* tersaturasi penuh.

Contoh dari Tabel IV.2: LFM 2.5 Q4_K_M mencatat 299,33% (sehat, sekitar tiga *thread* aktif), sedangkan LFM 2.5 Q3_K_M mencapai 464,00% yang mendekati saturasi penuh dan berisiko *thermal throttling*.

1.2.3 Prompt Speed (Prompt TPS, t/s)

Kecepatan model **membaca** dan **memproses prompt** masukan dari pengguna, dalam satuan *token per second*. Semakin tinggi, semakin cepat model “membaca soal”.

1.2.4 Generation Speed (Gen TPS, t/s)

Kecepatan model **menulis** jawaban, juga dalam *token per second*. Ini metrik paling penting bagi pengalaman pengguna karena menentukan seberapa cepat jawaban muncul.

Analogi: Kalau *Prompt Speed* itu seperti kecepatan **membaca soal**, maka *Generation Speed* itu kecepatan **menulis jawaban**.

1.2.5 Total Waktu Eksekusi (s)

Durasi total dari awal pemuatan model hingga jawaban selesai diproduksi. Mencakup waktu membaca *prompt* + waktu menulis jawaban.

1.2.6 Token

Unit teks terkecil yang diproses model. Bahasa Indonesia rata-rata satu kata terdiri dari 1–3 *token*; satu kalimat pendek biasanya 10–20 *token*; satu paragraf biasanya 80–150 *token*.

1.3 Istilah Performa Kognitif (Software / AI)

1.3.1 Perplexity (PPL)

Ukuran “kebingungan” model terhadap kalimat baru. Semakin **rendah** PPL, semakin baik model dalam memprediksi kata berikutnya pada teks. Berbeda dengan metrik lain, **PPL bersifat *inverse*: kecil lebih baik**.

Contoh dari Tabel IV.3: LFM 2.5 F16 punya PPL 12,6829 (terbaik); LFM 2.5 Q3_K_M punya PPL 14,5135 (sudah lebih bingung). Selisih 1,83 poin ini menandakan degradasi linguistik kecil tetapi terdeteksi.

1.3.2 MMLU (Massive Multitask Language Understanding)

Benchmark pilihan ganda A/B/C/D pada berbagai topik akademik (matematika, sejarah, hukum, biologi, dst.). Skor dalam persentase jawaban benar dari 100 sampel.

1.3.3 GSM8K (Grade School Math 8K)

Benchmark soal matematika tingkat SD/SMP dengan jawaban numerik. Skor dalam persentase jawaban benar. **Untuk Qwen 3.5 yang *reasoning model*, skor GSM8K dilaporkan sebagai *lower bound* akibat keterbatasan *parser* (lihat Sub-bab 4.3.3 di skripsi utama).**

1.3.4 HumanEval (Code Generation Benchmark)

Benchmark menulis fungsi Python sederhana yang lalu diuji melalui *unit-test*. Skor dalam persentase fungsi yang lolos *unit-test*.

1.3.5 MT-Bench TTR (Type-Token Ratio)

Skor keragaman leksikal jawaban generatif. TTR = jumlah kata unik / jumlah total kata. **Skala 0–1, semakin tinggi semakin beragam kosakatanya.** Pada tabel kadang ditampilkan dikalikan 100 (jadi skala 0–100) supaya satuannya sebanding dengan persentase akurasi.

Contoh: TTR 0,526 (= 52,6) artinya 52,6% kata pada jawaban model adalah kata unik (tidak terulang). Nilai 0,403 menandakan banyak pengulangan kata.

1.3.6 Retensi Kepintaran / Retensi Akurasi (%)

Persentase **akurasi rata-rata** sebuah varian terkuantisasi terhadap **baseline F16**. Rumusnya:

$$\text{Retensi (\%)} = \frac{\text{Rerata akurasi varian kuantisasi}}{\text{Rerata akurasi F16}} \times 100\%$$

Contoh dari Tabel IV.6: Rerata akurasi LFM 2.5 Q4_K_M adalah 37,3%, sedangkan rerata F16 42,0%. Retensi = $37,3 / 42,0 \times 100\% = 88,9\%$. Artinya Q4_K_M masih mempertahankan 88,9% kepintaran F16 (kehilangan 11,1%).

1.3.7 Delta (Δ) Akurasi

Selisih akurasi (dalam **poin persentase**) antara varian terkuantisasi dengan F16. Tanda + berarti naik, tanda – berarti turun.

Contoh dari Tabel IV.6: GSM8K LFM 2.5 di F16 = 58% dan di Q3_K_M = 40%, sehingga $\Delta Q3 = -18$. Artinya akurasi GSM8K **turun 18 poin** akibat kuantisasi ke Q3_K_M.

1.3.8 Compound Score

Skor gabungan untuk menilai *trade-off* antara kecepatan, retensi akurasi, dan konsumsi RAM. Rumusnya:

$$\text{Compound Score} = \frac{\text{Gen TPS} \times \text{Retensi Akurasi}}{\text{RAM}_{\text{GB}}} \times 1000$$

Interpretasi: Semakin tinggi, semakin baik. Skor ini mengukur “berapa banyak *token per second* yang berguna (sudah dikalikan retensi akurasi) yang bisa didapat per 1 GB RAM yang dikonsumsi”.

Contoh dari Tabel IV.7 (LFM 2.5 Q4_K_M):

Gen TPS = 13,67 t/s

Retensi akurasi = 88,9% = 0,889

RAM = 1.453 MB = 1,453 GB

Compound Score = $(13,67 \times 0,889) / 1,453 \times 1000 = 12,15 / 1,453 \times 1000 = 8.363 / 1000 = \mathbf{8,36}$

Skor 8,36 artinya Q4_K_M memberikan 8,36 unit “produktivitas inferensi” per GB RAM, jauh lebih baik daripada F16 (2,42) dan masih kompetitif terhadap Q3_K_M (9,44). Q3 unggul aritmetik karena RAM-nya kecil, tetapi penurunan akurasinya membuat Compound Score saja tidak cukup sebagai dasar rekomendasi.

1.4 Istilah Statistik (BAB 4.4.6)

1.4.1 N (Jumlah Replikasi)

Berapa kali eksperimen diulang untuk satu varian. Pada skripsi ini N=3 untuk seluruh varian, artinya setiap varian (F16, Q5, Q4, Q3) di kedua keluarga model (LFM dan Qwen) diuji tiga kali, lalu dihitung rerata dan simpangan baku.

1.4.2 Rerata (*mean*) dan Simpangan Baku (*standard deviation, std*)

Rerata = nilai rata-rata dari N pengulangan. Simpangan baku = ukuran “sebaran” data di sekitar rerata. Notasi pada tabel: **rerata $\pm$ std**.

Contoh: Gen TPS LFM 2.5 Q4_K_M = 13,67 $\pm$ 0,24 t/s artinya rata-rata 13,67 t/s, dengan std 0,24 t/s. Std kecil = data konsisten; std besar = data bervariasi antar pengulangan.

1.4.3 *t-test* / *Welch’s t-test*

Uji statistik untuk menentukan apakah **dua rerata** berbeda secara nyata atau hanya kebetulan. *Welch’s t-test* adalah varian yang tidak mengasumsikan kedua kelompok punya variansi yang sama, sehingga lebih **konservatif** (lebih sulit menyatakan “berbeda nyata”) dibanding *t-test* klasik. Penelitian ini memakai *Welch’s t-test* dengan taraf signifikansi $\alpha = 0,05$.

1.4.4 ANOVA (*Analysis of Variance*)

Uji statistik untuk menentukan apakah **tiga atau lebih kelompok** secara keseluruhan punya rerata yang berbeda. Hasilnya berupa nilai **F** dan **p-value**. Pada penelitian ini, ANOVA dipakai untuk menilai apakah keempat varian (F16, Q5, Q4, Q3) secara keseluruhan benar-benar beda.

1.4.5 *p*-value (Nilai *p*)

Probabilitas (skala 0–1) bahwa perbedaan rerata yang teramati hanyalah **kebetulan**.

$p < 0,05$ -> perbedaan dianggap **nyata** secara statistik (signifikan), ditandai dengan dua bintang **.

$p \geq 0,05$ -> perbedaan belum cukup bukti untuk dinyatakan nyata, ditandai dengan n . s . (*not significant*).

Analogi: Bayangkan kamu melempar dadu dan keluar angka 6 sebanyak tiga kali berturut-turut. Apakah dadu curang atau hanya kebetulan? *p*-value adalah peluang dadu jujur tetapi tetap menghasilkan tiga angka 6 berturut-turut. Kalau peluangnya kurang dari 5%, kita berani menyatakan dadu memang curang.

1.4.6 Notasi pada Tabel IV.8 dan IV.9

Pada tabel statistik:

$p < 0,001$ ** artinya perbedaan **sangat meyakinkan** (peluang kebetulan kurang dari 0,1%).

$p = 0,024$ ** artinya perbedaan **meyakinkan** (peluang kebetulan 2,4%).

$p = 0,548$ (n . s .) artinya perbedaan **tidak meyakinkan** (peluang kebetulan 54,8%).

Kolom **Ringkasan** di ujung kanan menjelaskan hasil tiap baris dalam satu kalimat, agar tabel cepat dibaca tanpa harus menerjemahkan angka *p* secara manual.

Bagian 2: Panduan Membaca Tabel BAB III

2.1 Tabel III.0 – Pemetaan Langkah MobileAIBench ke Tahap Penelitian

Fungsi: Menjelaskan bagaimana lima tahap penelitian ini (Sub-bab 3.1) sejalan dengan kerangka *workflow* enam langkah MobileAIBench (Murthy dkk., 2024).

Cara baca:

Kolom kiri = nama langkah pada *workflow* MobileAIBench.

Kolom kanan = tahap penelitian yang mengisinya pada skripsi ini.

Contoh interpretasi: “Step 1–2 (*Task/Dataset Identification* + *Data Preprocess/Loading*) -> Tahap 1 (Studi Pendahuluan)” berarti dua langkah pertama MobileAIBench dikerjakan secara terpadu dalam Tahap 1.

2.2 Tabel III.1 – Spesifikasi Perangkat Keras

Fungsi: Mendokumentasikan dua *host* yang dipakai pada eksperimen.

Cara baca:

Peran – jenis tugas yang ditangani *host* tersebut (persiapan model & evaluasi akurasi, vs. *target deployment*).

Komponen – nama komponen perangkat keras.

Spesifikasi – detail teknis komponen.

Keterangan – catatan tambahan, misalnya mengapa RAM 8 GB jadi *bottleneck*.

Catatan penting: RAM 8 GB pada Tecno Pova 5 menjadi *limit* paling ketat karena memori dipakai bersama OS Android, sehingga eksekusi model FP16 berisiko memicu *OOM Killer*.

2.3 Tabel III.2 – Spesifikasi Perangkat Lunak

Fungsi: Mencantumkan *toolchain* lengkap di kedua *host*.

Cara baca: Sama dengan Tabel III.1, tetapi kolom “Komponen” diisi oleh perangkat lunak (sistem operasi, *library*, skrip).

Contoh interpretasi: Baris “PC persiapan / Konversi & kuantisasi / `convert_hf_to_gguf.py`, `./llama-quantize`” menunjukkan bahwa proses konversi `.safetensors` -> `.gguf` dan kuantisasi ke Q5/Q4/Q3_K_M semua dilakukan di PC, bukan di *smartphone*.

Bagian 3: Panduan Membaca Tabel BAB IV

3.1 Tabel IV.1 – Reduksi Ukuran Berkas Model

Fungsi: Menunjukkan seberapa kecil berkas .gguf setelah dikuantisasi.

Cara baca:

Model Arsitektur – LFM 2.5 atau Qwen 3.5.

Presisi / Format – F16, Q5_K_M, Q4_K_M, atau Q3_K_M.

Ukuran Berkas – ukuran fisik pada penyimpanan internal.

Persentase Reduksi – penurunan ukuran berkas terhadap F16 *baseline* keluarga model yang sama.

Contoh interpretasi: LFM 2.5 Q4_K_M berukuran 698 MB, turun 68,27% dari F16 yang 2,2 GB. Artinya kuantisasi 4-bit pada LFM menghemat dua pertiga ukuran penyimpanan.

Implikasi praktis: Penghematan ini langsung berarti pengguna *smartphone* dengan ROM 64–128 GB bisa menyimpan lebih banyak model sekaligus.

3.2 Tabel IV.2 – Performa Inferensi (Tabel Terpadat)

Fungsi: Tabel utama BAB IV. Mencatat lima metrik *hardware* untuk delapan varian (4 varian $\times$ 2 keluarga model).

Kolom-kolomnya:

N – jumlah replikasi (selalu 3 pada penelitian ini).

Total Waktu (s) – durasi sebuah sesi inferensi dari awal hingga akhir.

Prompt Speed (t/s) – kecepatan baca *prompt* (lihat 1.2.3).

Gen Speed (t/s) – kecepatan tulis jawaban (lihat 1.2.4).

Peak RAM Proses (MB) – konsumsi RAM puncak (lihat 1.2.1).

CPU Peak (%) – beban CPU puncak (lihat 1.2.2; skala 0–600%).

Cara membaca satu baris (contoh: LFM 2.5 Q4_K_M):

“3 | 7,33 $\pm$ 0,47 | 43,67 $\pm$ 2,38 | 13,67 $\pm$ 0,24 | 1.452,97 $\pm$ 14,15 | 299,33 $\pm$ 19,69”

Artinya: pada 3 kali pengulangan, sesi inferensi rata-rata selesai dalam 7,33 detik, model membaca *prompt* di 43,67 t/s, menulis jawaban di 13,67 t/s, memakai RAM puncak 1.452,97 MB, dan CPU puncaknya 299,33% (tiga *thread* aktif penuh). Std-nya kecil (mis. 0,47 detik) berarti hasil ketiga pengulangan konsisten.

Cara membandingkan antar varian:

1. Tetapkan satu kolom metrik (mis. *Peak* RAM).
2. Bandingkan F16 vs Q5 vs Q4 vs Q3 dalam keluarga model yang sama.
3. Hitung persentase penurunan/peningkatan dengan rumus *delta* standar: $\frac{\text{nilai varian} - \text{nilai F16}}{\text{nilai F16}} \times 100\%$.

3.3 Tabel IV.3 – *Perplexity* (PPL)

Fungsi: Mengukur degradasi linguistik akibat kuantisasi pada dataset WikiText-2.

Cara baca: Kolom-kolomnya adalah varian (F16 sampai Q3_K_M), dan baris-barisnya adalah dua keluarga model. **Nilai kecil = model lebih “pintar” memahami bahasa.**

Contoh interpretasi: LFM 2.5 PPL naik dari 12,6829 (F16) menjadi 14,5135 (Q3_K_M). Pelebaran 1,83 poin ini relatif kecil di atas *baseline* yang sudah 12 poin, sehingga degradasi linguistik LFM secara umum masih dapat diterima.

3.4 Tabel IV.4 – Akurasi LFM 2.5

Fungsi: Mencatat akurasi LFM 2.5 pada empat *benchmark* kognitif.

Cara baca:

Baris – jenis *benchmark* (MMLU, GSM8K, HumanEval, MT-Bench TTR).

Kolom – varian kuantisasi (F16, Q5, Q4, Q3).

Nilai – skor akurasi (% untuk tiga *benchmark* pertama; rasio 0–1 untuk MT-Bench TTR).

Catatan margin error: Karena setiap *benchmark* dijalankan dengan $n=100$ sampel, **selisih ≤ 10 poin antar varian belum tentu bermakna** secara statistik (margin error 95% CI $\approx \pm 10$ poin pada distribusi biner pass/fail).

3.5 Tabel IV.5 – Akurasi Qwen 3.5

Fungsi: Sama dengan Tabel IV.4, tetapi untuk Qwen 3.5.

Perhatian khusus pada GSM8K: Qwen 3.5 adalah *reasoning model* (menghasilkan blok `<think>...</think>` sebelum jawaban). Skor GSM8K yang rendah (12–19%) **bukan menandakan model bodoh**, tetapi keterbatasan *parser* yang sering tidak menangkap jawaban akhir sebelum anggaran *token* habis. Penjelasan lengkap di Sub-bab 4.3.3.

3.6 Tabel IV.6 – *Delta* Akurasi LFM 2.5

Fungsi: Menghitung **selisih akurasi** tiap varian terhadap F16, beserta **rata-rata** dan **retensi**.

Cara baca kolom:

F16 (kontrol) – skor *baseline*.

Q5_K_M dan **$\Delta Q5$** – skor varian Q5 dan selisihnya terhadap F16. Contoh: MMLU F16 = 32%, Q5 = 34%, $\Delta Q5 = +2$ poin (naik 2 poin).

Q4_K_M dan **$\Delta Q4$** – demikian pula untuk Q4.

Q3_K_M dan **$\Delta Q3$** – demikian pula untuk Q3.

Baris terakhir:

Rata-rata akurasi tiga *benchmark* – rerata aritmetik dari MMLU, HumanEval, dan MT-Bench TTR (skala disetarakan $\times 100$). GSM8K tidak dimasukkan ke rerata pada Tabel IV.6-B (Qwen) karena keterbatasan *parser*; untuk LFM 2.5 di Tabel IV.6, GSM8K **ikut** dihitung.

Retensi kepintaran – persentase rerata varian terhadap rerata F16. Contoh: Q4 LFM = 37,3% / 42,0% = 88,9%.

Tabel IV.6 untuk LFM termasuk GSM8K karena LFM bukan *reasoning model* dan skor GSM8K-nya valid.

Tabel IV.6-B untuk Qwen tidak menyertakan GSM8K dalam rerata karena skor tersebut berada di bawah margin instrumen.

3.7 Tabel IV.7 – Matriks Rekomendasi LFM 2.5

Fungsi: Tabel pengambilan keputusan. Menggabungkan empat metrik (RAM, Gen TPS, Total Waktu, Retensi Akurasi, CPU *Peak*) menjadi satu skor: ***Compound Score***.

Cara baca:

Varian – pilihan F16 hingga Q3_K_M.

Peak RAM (MB) – ambil dari Tabel IV.2.

Gen TPS (t/s) – ambil dari Tabel IV.2.

Total Waktu (s) – ambil dari Tabel IV.2.

Retensi Akurasi – ambil dari Tabel IV.6 (baris paling bawah).

CPU Peak (%) – ambil dari Tabel IV.2.

Compound Score – dihitung dengan rumus di Sub-bab 1.3.8 manual ini.

Cara memutuskan varian terbaik:

1. Lihat dua varian dengan *Compound Score* tertinggi (Q4 = 8,36 dan Q3 = 9,44).

2. Periksa apakah skor tertinggi (Q3) punya **risiko** lain: CPU *peak* (464% mendekati saturasi), GSM8K (turun 18 poin), dan anomali *Prompt Speed* (18,27 t/s < 43,67 t/s pada Q4).
3. Pilih varian dengan *trade-off* paling sehat. Dalam penelitian ini: **Q4_K_M** terpilih karena *Compound Score*-nya tinggi (8,36) tanpa risiko *thermal* atau *code-collapse*.

3.8 Tabel IV.6-B – Delta Akurasi Qwen 3.5

Fungsi: Identik dengan Tabel IV.6, tetapi untuk Qwen 3.5.

Yang harus diperhatikan: Rerata Qwen **hanya dari tiga benchmark** (MMLU, HumanEval, MT-Bench TTR×100). GSM8K dilaporkan apa adanya pada baris GSM8K, tetapi **tidak ikut** dihitung pada baris “Rata-rata”.

Contoh interpretasi: Qwen Q3_K_M punya MMLU 40% (sama persis dengan F16, $\Delta Q3 = \pm 0$) tetapi HumanEval anjlok 27 poin (52% -> 25%). Artinya kuantisasi 3-bit menggerus kemampuan *coding* Qwen jauh lebih parah daripada kemampuan pemahaman umum.

3.9 Tabel IV.7-B – Matriks Rekomendasi Qwen 3.5

Fungsi: Identik dengan Tabel IV.7, tetapi untuk Qwen.

Cara baca dan analisis sama persis dengan Tabel IV.7. Hasilnya: Q4_K_M kembali jadi rekomendasi (Compound Score 1,76) meskipun Q3_K_M aritmetik unggul (1,79), karena Q3 menyebabkan *code-collapse* (HumanEval -27 poin) dan CPU *peak* tertinggi (525%).

Mengapa skor Qwen jauh lebih kecil daripada LFM? Karena Qwen 3.5 jenuh di 4–5 t/s pada CPU Helio G99, sedangkan LFM 2.5 mencapai 13–14 t/s. Rumus *Compound Score* sangat sensitif terhadap Gen TPS, sehingga model 2B parameter pada CPU kelas menengah otomatis menerima skor lebih kecil. Ini bukan berarti Qwen “kalah”, melainkan ada *hardware ceiling* yang sama-sama dialami semua varian Qwen.

3.10 Tabel IV.8 – Uji Statistik LFM 2.5

Fungsi: Mengonfirmasi apakah selisih rerata pada Tabel IV.2 benar-benar nyata atau cuma kebetulan.

Cara baca per baris (contoh: F16 vs Q5_K_M):

Pasangan Varian – dua varian yang dibandingkan.

Gen TPS | $p = 0,004$ ** -> perbedaan Gen TPS antara F16 dan Q5 meyakinkan (peluang kebetulan 0,4%).

Prompt TPS | $p = 0,726$ (n.s.) -> perbedaan Prompt TPS antara F16 dan Q5 belum cukup bukti meyakinkan (peluang kebetulan 72,6%).

Peak RAM | $p < 0,001$ ** -> perbedaan RAM sangat meyakinkan.

Ringkasan – “Gen & RAM berbeda nyata; Prompt tidak”.

Baris paling bawah (ANOVA): Mengukur apakah keempat varian secara keseluruhan memang berbeda. ANOVA $p < 0,001$ pada ketiga metrik menunjukkan: ya, kuantisasi benar-benar memberi dampak yang signifikan.

3.11 Tabel IV.9 – Uji Statistik Qwen 3.5

Fungsi: Sama dengan Tabel IV.8, tetapi untuk Qwen 3.5.

Pola penting yang harus diperhatikan:

1. **Reduksi RAM Qwen lebih dramatis** dibanding LFM (semua pasangan $p < 0,001$).
2. **Gen TPS Qwen saturasi:** F16 vs Q5/Q4/Q3 signifikan (kuantisasi mempercepat), tetapi antar Q5/Q4/Q3 tidak signifikan ($p = 0,054-0,260$). Artinya begitu Qwen dikuantisasi, kecepatannya “menabrak langit-langit” di 4–5 t/s tidak peduli levelnya.
3. **Anomali Prompt Speed Q3** kembali muncul (F16 vs Q3 signifikan, Q4 vs Q3 signifikan), mengonfirmasi pola *unpacking* bit ganjil pada CPU ARM (Sub-bab 4.4.2).

Bagian 4: Ringkasan Pengambilan Keputusan

Tabel ringkas berikut membantu pembaca memilih varian yang sesuai dengan kebutuhan:

Table 1: Tabel M.1 Ringkasan Pengambilan Keputusan Varian Kuantisasi

Kondisi Pengguna	Varian Disarankan	Alasan Utama
Butuh akurasi maksimal, tidak peduli RAM/kecepatan	F16	Tidak ada degradasi akurasi
Butuh akurasi tinggi, RAM longgar (≥ 4 GB ruang model)	Q5_K_M	Retensi akurasi tertinggi di antara varian terkuantisasi
Butuh keseimbangan terbaik (RAM 8 GB)	Q4_K_M	<i>Sweet spot: Compound Score tinggi tanpa risiko termal</i>
Butuh ukuran berkas paling kecil, akurasi sekunder	Q3_K_M	Cocok untuk <i>use case</i> non-matematis dan non-coding

Bagian 5: Penjelasan Notasi dan Simbol

Table 2: Tabel M.2 Daftar Notasi dan Simbol

Notasi	Arti
N	Jumlah replikasi eksperimen (selalu 3)
$\pm$	Rerata $\pm$ simpangan baku
Δ (Delta)	Selisih terhadap <i>baseline</i> F16 (point persentase)
p	<i>p-value</i> uji statistik
**	Berbeda nyata ($p < 0,05$), signifikan
n . s .	<i>Not significant</i> , tidak berbeda nyata ($p \geq 0,05$)
	Taraf signifikansi ($0,05 = 5\%$)
F	Statistik F pada ANOVA
t	Statistik t pada Welch's <i>t-test</i> (semakin jauh dari 0, semakin kuat perbedaan)
$\downarrow$	Penurunan/Reduksi (mis. ukuran berkas)
t/s	<i>Tokens per second</i>

Bagian 6: Catatan Penutup

Manual book ini disusun sebagai pelengkap naskah utama dan dirancang agar dapat digunakan secara mandiri. Pembaca yang ingin meninjau metodologi penelitian, hasil eksperimen, dan pembahasan analisis tetap disarankan untuk membaca naskah utama (BAB I–V). Sumber data mentah dan skrip reproduksi tersedia pada folder `docs/data/` dan `docs/scripts/`, sedangkan dokumen-dokumen pendukung tersedia pada folder `docs/lampiran/`.

Apabila terdapat ketidakjelasan pada definisi istilah atau cara membaca tabel, mohon merujuk pertama kali ke manual book ini, kemudian ke naskah utama untuk konteks penuhnya.