

ANALISIS PERFORMA POST-TRAINING QUANTIZATION (PTQ) PADA SMALL LANGUAGE MODEL UNTUK IMPLEMENTASI EDGE COMPUTING BERBASIS ANDROID

Penulis: [Nama Mahasiswa] — NIM: [NIM]

Program Studi Teknologi Informasi — Fakultas Teknik dan
Informatika — Universitas Bina Sarana Informatika

DAFTAR ISI

ABSTRAK	3
KATA PENGANTAR	4
BAB I — PENDAHULUAN	5
1.1 Latar Belakang Masalah	5
1.2 Identifikasi Permasalahan	7
1.3 Perumusan Masalah	8
1.4 Tujuan dan Manfaat	8
1.4.1 Tujuan Penelitian	8
1.4.2 Manfaat Penelitian	9
1.5 Metode Penelitian	10
1.6 Teknik Pengumpulan Data	10
A. Observasi (Eksperimental)	10
B. Studi Pustaka	10
1.7 Ruang Lingkup	11
1.8 Hipotesis	12
BAB II — LANDASAN TEORI	13
2.1 Tinjauan Pustaka	13
2.1.1 Natural Language Processing (NLP) dan Pergeseran ke Edge Computing	13
2.1.2 Large Language Models (LLM) dan Fleksibilitasnya	14
2.1.3 Small Language Models (SLM) dan Limitasi Perangkat Seluler	14
2.1.4 Arsitektur Dasar Transformer	15

2.1.5 Konsep Kuantisasi, Presisi Campuran (K-Quants), dan Rentang 3-Bit hingga 5-Bit	15
2.1.6 Karakteristik Inferensi Mobile: Limitasi CPU dan Bandwidth Memori	16
2.1.7 Format File GGUF (GPT-Generated Unified Format)	17
2.1.8 Framework Inferensi llama.cpp di Android	17
2.1.9 Tantangan Gangguan Matematis (Perturbation)	18
2.1.10 Metrik Evaluasi Performa Edge Computing	18
2.1.11 Standar Pengujian Kognitif dan Linguistik	18
2.2 Penelitian Terkait	19
2.3 Tinjauan Objek Penelitian	25
2.3.1 Ekosistem Uji Keras: Tecno Pova 5 dengan Termux	25
2.3.2 Objek Arsitektur SLM: LFM 2.5 (1,2B) dan Qwen 3.5 (2B)	26
BAB III — METODOLOGI PENELITIAN	27
3.1 Tahapan Penelitian	27
3.2 Instrumen Penelitian	29
3.3 Metode Pengumpulan Data	30
A. Pengamatan Langsung (Observasi Eksperimental)	31
B. Studi Pustaka	31
3.4 Metode Analisis Data	31
BAB IV — HASIL PENELITIAN DAN PEMBAHASAN	33
4.1 Lingkungan Pengujian dan Skenario	33
4.2 Hasil Uji Efisiensi Infrastruktur (Hardware)	33
4.2.1 Reduksi Kapasitas Penyimpanan Fisik (Storage)	33
4.2.2 Konsumsi RAM dan Kecepatan Inferensi (Helio G99)	35
4.3 Hasil Uji Degradasi Kognitif (Software / AI)	38
4.3.1 Evaluasi Perplexity (PPL)	38
4.3.2 Evaluasi Akurasi Logika (MMLU, GSM8K, dan HumanEval) serta Kreativitas Bahasa (MT-Bench TTR)	39
4.3.3 Keterbatasan Evaluasi Akurasi pada Reasoning Model (Qwen 3.5)	41
4.4 Pembahasan Analisis Komparatif	42
4.4.1 Efisiensi RAM dan Peningkatan Generation Speed	42
4.4.2 Anomali Kecepatan Baca (Prompt Speed) pada Varian Q3_K_M	43
4.4.3 Dampak Distorsi terhadap Nalar Matematika dan Logika Pemrograman	43
4.4.4 Penetapan Titik Keseimbangan Optimal (Sweet Spot)	44
BAB V — PENUTUP	46
5.1 Kesimpulan	46
5.2 Keterbatasan Penelitian	47
5.3 Saran	48
DAFTAR PUSTAKA	49

ABSTRAK

Pemanfaatan Small Language Model (SLM) secara on-device di lingkungan Android terkendala oleh kapasitas RAM 8 GB yang dibagi-pakai (shared memory) bersama sistem operasi dan layanan latar belakang, sehingga pemuatan model presisi penuh FP16 berisiko memicu Out of Memory (OOM) dan Force Close. Penelitian ini menganalisis performa metode Post-Training Quantization (PTQ) dengan format GGUF k-quants pada rentang 3-bit hingga 5-bit (Q3_K_M, Q4_K_M, dan Q5_K_M) terhadap dua arsitektur SLM, yaitu LFM 2.5 (1,2 miliar parameter) dan Qwen 3.5 (2 miliar parameter), pada perangkat Tecno Pova 5 (SoC MediaTek Helio G99, RAM 8 GB) melalui lingkungan terminal Termux dan mesin inferensi llama.cpp. Metode yang digunakan adalah eksperimen kuantitatif komparatif (ablation study) dengan mengukur (1) reduksi ukuran berkas, (2) konsumsi peak RAM proses, (3) kecepatan prompt dan generation dalam satuan tokens per second (TPS), serta (4) degradasi kognitif melalui Perplexity (WikiText-2) dan akurasi MMLU, GSM8K, HumanEval, dan MT-Bench. Setiap varian model di Android diuji dua hingga tiga kali untuk memperoleh rerata $\pm$ simpangan baku. Hasil menunjukkan bahwa varian Q4_K_M merupakan titik keseimbangan (sweet spot) terbaik karena mampu menekan ukuran berkas hingga 68%, mereduksi peak RAM proses LFM dari 2.303 MB ke 1.453 MB (efisiensi 36,9%), serta mempercepat generation LFM dari 5,57 t/s ke 13,67 t/s (akselerasi 2,45 $\times$), dengan tambahan perplexity di bawah 0,6 poin dan rata-rata penurunan akurasi LFM yang masih dapat ditoleransi. Sebaliknya, varian Q3_K_M memicu anomali bit-shifting pada CPU ARM serta degradasi GSM8K dan HumanEval yang signifikan, sehingga tidak direkomendasikan sebagai konfigurasi produksi. Penelitian juga mendokumentasikan keterbatasan instrumen evaluasi pada model reasoning Qwen 3.5 sebagai catatan metodologis penting untuk replikasi.

Kata kunci: Post-Training Quantization, Small Language Model, Edge Computing, GGUF, k-quants, Android, Helio G99, Perplexity.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas selesainya penyusunan skripsi yang berjudul **“Analisis Performa Post-Training Quantization (PTQ) pada Small Language Model untuk Implementasi Edge Computing Berbasis Android”**. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan program sarjana pada Program Studi Teknologi Informasi, Fakultas Teknik dan Informatika, Universitas Bina Sarana Informatika.

Penulis menyampaikan terima kasih kepada dosen pembimbing, rekan-rekan mahasiswa, serta keluarga yang telah memberikan dukungan moral, masukan teknis, dan akses sumber daya selama proses penelitian berlangsung. Penulis menyadari bahwa skripsi ini masih jauh dari sempurna, sehingga kritik dan saran yang membangun sangat diharapkan demi penyempurnaan karya tulis serupa di masa depan.

Jakarta, [Tanggal] [Bulan] [Tahun]

Penulis,

[Nama Mahasiswa]

BAB I — PENDAHULUAN

1.1 Latar Belakang Masalah

Lanskap teknologi kecerdasan buatan, terkhusus pada domain Natural Language Processing (NLP), saat ini mengalami disrupsi fundamental akibat penetrasi Large Language Models (LLM). Model berskala masif ini telah mendefinisikan ulang batas atas kemampuan komputasi mesin dalam menguraikan makna semantik dan membangkitkan teks yang setara dengan gaya kognitif manusia. Kendati menawarkan performa luar biasa, arsitektur LLM kontemporer menuntut spesifikasi infrastruktur komputasi—terutama Graphics Processing Unit (GPU)—yang besar dan eksklusif. Ketergantungan absolut pada perangkat keras kelas atas ini pada akhirnya memicu fenomena defisit alokasi memori (Out of Memory) yang pasti terjadi apabila model dipaksakan beroperasi di atas perangkat keras komputasi reguler milik konsumen akhir (Touvron dkk., 2023).

Di sisi lain, pergeseran paradigma mobilitas digital meningkatkan tuntutan masyarakat akan asisten virtual pintar yang proaktif dan responsif secara real-time tanpa latensi jaringan. Kebutuhan praktis ini terlihat pada berbagai implementasi sektoral yang krusial, mulai dari layanan sistem informasi rumah sakit (Ahmad & Safudin, 2024) hingga integrasi simpul LLM dalam infrastruktur pemantauan jaringan nirkabel pada ekosistem kawasan urban (Sevim & Ibrahim, 2024). Namun, pemanfaatan layanan AI terpusat melalui Cloud API komersial menghadirkan eskalasi risiko keamanan yang fatal, terutama yang bersinggungan dengan jaminan privasi data pengguna. Untuk merespons ancaman tersebut, para ahli keamanan siber merekomendasikan agar pemrosesan AI dilokalisasi: eksekusi inferensi harus bergeser untuk dioperasikan secara otonom dan offline di titik terluar jaringan (Edge Device), seperti pada smartphone bersistem operasi Android. Langkah mitigasi ini esensial guna meredam potensi kebocoran rekam medis, rahasia korporat, maupun pangkalan data pribadi masyarakat (Zhan dkk., 2025).

Sebagai antitesis atas tuntutan privasi tersebut, Small Language Models

(SLM) dirancang dengan rasio pemangkasan parameter yang signifikan agar lebih akomodatif terhadap kapasitas komputasi perangkat personal. Sayangnya, hambatan mekanis justru berasal dari fondasi arsitektur fisik gawai konsumen. Rata-rata smartphone kelas menengah hanya dibekali RAM 8 GB. Persoalan menjadi kian rumit karena kapasitas terbatas ini mengusung topologi Unified Memory, sebuah sistem di mana alokasi RAM harus dibagi-pakai (shared memory) dan diperebutkan secara ketat oleh sistem operasi Android beserta layanan latar belakang. Arsitektur tersebut tidak dirancang untuk menahan beban matriks model AI yang masih berwujud presisi tinggi 16-bit (Floating-Point/FP16). Apabila pemuatan model orisinal tetap dipaksakan, utilitas pengawas memori bawaan Android (Low Memory Killer Daemon) akan memicu protokol intervensi perlindungan dan mengeksekusi Force Close. Demi menghindari kelumpuhan operasional ini, optimasi Edge Intelligence menjadi prosedur yang mutlak diselenggarakan (Zhang dkk., 2024).

Salah satu intervensi komputasional paling krusial untuk menekan memory footprint—sehingga model AI dapat dimuat secara aman ke dalam sempitnya RAM smartphone—adalah melalui Post-Training Quantization (PTQ). Berbagai kajian terkini memvalidasi bahwa teknik pemadatan bobot menuju tingkat presisi menengah ke bawah (3-bit hingga 5-bit) terbukti secara empiris mampu mereduksi kebutuhan memori hingga kurang dari sepertiga dimensi aslinya, tanpa perlu melewati fase pelatihan ulang yang mahal (Dettmers dkk., 2023; Frantar dkk., 2023). Walaupun skema PTQ menawarkan efisiensi yang menjanjikan, mutilasi presisi pada matriks bobot tidak luput dari ancaman gangguan matematis (perturbation). Proses pemotongan presisi ini berisiko menghilangkan sebaran komponen parameter ekstrem yang berperan sebagai jangkar jaringan (outliers). Hilangnya outliers dapat bermuara pada degradasi akurasi logika kognitif serta kualitas tata bahasa model (Gong dkk., 2024).

Berangkat dari rangkaian determinan pada ekosistem mobile edge computing tersebut, penelitian ini difokuskan pada pengujian empiris atas performa algoritma kompresi PTQ dengan pendekatan presisi campuran

(mixed-precision k-quants) yang dikonfigurasi bergradasi dari 3-bit hingga 5-bit (varian Q3_K_M, Q4_K_M, dan Q5_K_M). Target utama eksperimen ini adalah melokalisasi inferensi murni di dalam emulator terminal Android (Termux). Melalui matriks pengujian terstruktur pada dua SLM dengan ukuran berbeda (1,2 miliar dan 2 miliar parameter), penelitian ini bertujuan membuktikan secara empiris batas efektivitas kompresi yang paling sanggup menyelamatkan margin RAM dari Force Close, sembari menginvestigasi akselerasi Tokens per Second (TPS) pada CPU ARM dan signifikansi degradasi Perplexity yang menyertainya.

1.2 Identifikasi Permasalahan

Berdasarkan elaborasi latar belakang, dapat ditarik beberapa permasalahan utama yang menjadi fokus penelitian ini, yaitu:

1. **Kerentanan privasi pada arsitektur komputasi cloud.** Terdapat ketergantungan absolut pada layanan cloud komersial untuk pemrosesan instruksi LLM, yang rentan terhadap peretasan dan kebocoran data sensitif. Hal ini memicu urgensi akan hadirnya sistem AI otonom yang murni beroperasi secara offline langsung dari edge device pengguna.
2. **Limitasi arsitektur RAM pada on-device deployment.** Kapasitas RAM Android rata-rata 8 GB rawan mengalami krisis memori (Out of Memory) sehingga memicu Force Close saat memuat model FP16. Hingga kini belum ditemukan landasan empiris yang memetakan tingkat kompresi ideal yang paling seimbang dan aman untuk menetralkan anomali tersebut pada lingkungan shared memory Android.
3. **Risiko penurunan kecerdasan akibat kompresi ekstrem.** Pemadatan matriks SLM ke format ketat (Q3_K_M hingga Q5_K_M) menyimpan bahaya laten berupa halusinasi model dan meluruhnya kapabilitas nalar AI. Masih terdapat research gap yang signifikan mengenai persentase degradasi kecerdasan tatkala mesin dipaksa beroperasi di bawah tekanan kompresi tertingginya pada smartphone.

1.3 Perumusan Masalah

Berdasarkan identifikasi permasalahan di atas, rumusan masalah yang akan dijawab oleh penelitian ini adalah:

1. Berapa besar efisiensi penyimpanan (storage efficiency) dan reduksi konsumsi RAM yang dihasilkan oleh setiap varian kuantisasi GGUF (Q3_K_M, Q4_K_M, dan Q5_K_M) terhadap baseline FP16 pada model LFM 2.5 (1,2B) dan Qwen 3.5 (2B)?
2. Bagaimana perbandingan kualitas linguistik—diwakili oleh Perplexity (WikiText-2)—serta akurasi kognitif (MMLU, GSM8K, dan HumanEval) yang dipertahankan oleh masing-masing varian kuantisasi terhadap baseline FP16?
3. Seberapa besar peningkatan kecepatan inferensi (Prompt Processing t/s dan Text Generation t/s) yang dapat dicapai pada perangkat MediaTek Helio G99 dengan RAM 8 GB melalui kompresi PTQ?
4. Berdasarkan tinjauan trade-off multi-dimensi (efisiensi penyimpanan, RAM, TPS, Perplexity, dan akurasi), varian model dan tingkat kuantisasi mana yang paling optimal untuk diterapkan pada smartphone berkapasitas RAM 8 GB?

1.4 Tujuan dan Manfaat

1.4.1 Tujuan Penelitian

1. Mengimplementasikan dan mengevaluasi kelayakan operasional varian PTQ presisi campuran (Q3_K_M, Q4_K_M, dan Q5_K_M) pada arsitektur SLM, sekaligus mengidentifikasi batas aman toleransi RAM Android terhadap pemicu Force Close.
2. Melakukan komparasi faktual melalui benchmarking yang membandingkan perilaku model FP16 dengan ketiga varian kuantisasinya, guna membuktikan persentase efisiensi alokasi RAM, akselerasi Tokens per Second (TPS), serta fluktuasi degradasi Perplexity dan akurasi MMLU/GSM8K/HumanEval.
3. Menetapkan rekomendasi konfigurasi (model parameter-size dan

tingkat kuantisasi) yang paling optimal sebagai sweet spot operasional untuk perangkat Android berkapasitas RAM 8 GB.

1.4.2 Manfaat Penelitian

Bagi Penulis:

- a. Sebagai sarana pemenuhan salah satu syarat akademik untuk meraih kelulusan pada Program Sarjana, Program Studi Teknologi Informasi, Fakultas Teknik dan Informatika, Universitas Bina Sarana Informatika.
- b. Memperluas wawasan dan pengalaman praktis terkait implementasi Mobile Edge Computing serta strategi optimasi arsitektur kecerdasan buatan di lingkungan seluler yang terbatas.
- c. Menjadi sarana penerapan teori perkuliahan, khususnya pada irisan multidisiplin Machine Learning, arsitektur perangkat keras mikro, dan algoritma pengolahan bahasa alami (NLP).

Bagi Objek Penelitian (Pengembang Aplikasi Edge AI):

- a. Menyediakan pedoman purwarupa operasional bagi perancangan infrastruktur AI yang memberikan garansi keamanan privasi data, karena interaksi dilangsungkan secara lokal (offline).
- b. Menawarkan alternatif resolusi finansial guna menekan biaya pemeliharaan IT, di mana pengguna atau korporasi tidak lagi tergantung pada layanan Cloud API komersial berbiaya bulanan.
- c. Menghasilkan basis data telemetri yang presisi mengenai daya tahan RAM 8 GB Android terhadap beban eksekusi model AI pasca-kompresi.
- d. Memberikan rekomendasi format bagi para pengembang independent developer guna merakit chatbot pintar yang tertanam (embedded) di gawai kelas menengah.

Bagi Pembaca:

Membuka cakrawala pemahaman teoretis maupun operasional bagi pembaca akademik dan praktisi industri perihal anatomi teknik kompresi PTQ,

berikut tata laksana deployment SLM secara offline dan mandiri pada perangkat Android.

1.5 Metode Penelitian

Penelitian ini menggunakan pendekatan **empiris kuantitatif eksperimental**. Kerangka kerja dirancang untuk memfasilitasi pemantauan utilitas perangkat keras yang presisi, merekam indikator efisiensi memori, dan menguji tingkat kecerdasan AI pada ekosistem komputasi seluler. Eksperimen dilaksanakan sepenuhnya on-device pada smartphone Tecno Pova 5 melalui terminal emulator Termux, dengan mesin inferensi `llama.cpp` yang dikompilasi ulang secara natif untuk CPU ARM Helio G99. Setiap varian PTQ dijalankan melalui skenario terstandarisasi yang sama (jumlah token prompt, jumlah thread, dan dataset evaluasi) agar perbedaan performa benar-benar dapat dikaitkan dengan tingkat kompresi, bukan variabel eksternal.

1.6 Teknik Pengumpulan Data

A. Observasi (Eksperimental)

Observasi dilakukan dengan mengekstraksi log secara deterministik atas seluruh dinamika perangkat keras dan perangkat lunak di dalam Termux saat siklus inferensi AI berjalan. Konsumsi peak RAM diamati melalui utilitas `htop`, sedangkan metrik Tokens per Second (TPS) dan Perplexity diekstraksi dari keluaran backend `llama.cpp` (modul `./llama-bench` dan `./llama-perplexity`). Pencatatan dilakukan pada setiap transisi resolusi kompresi (FP16, Q5_K_M, Q4_K_M, dan Q3_K_M) untuk kedua model.

B. Studi Pustaka

Studi pustaka dilakukan dengan menghimpun dan memetakan referensi dari berbagai karya tulis ilmiah, baik jurnal nasional maupun internasional, yang dipublikasikan pada rentang 2023–2026. Fokus telaah literatur men-

cakup teori fundamental arsitektur LLM/SLM (Touvron dkk., 2023), teori gangguan matematis pada kuantisasi (Gong dkk., 2024), pedoman Edge Intelligence (Zhang dkk., 2024), serta validasi empiris penerapan `llama.cpp` di perangkat ARM dengan sumber daya terbatas (Ray & Pradhan, 2026). Referensi pilar dari Dettmers dkk. (2023), Frantar dkk. (2023), Lin dkk. (2023), dan Jin dkk. (2024) digunakan sebagai instrumen landasan teori sekaligus pemandu standar parameter kalibrasi pada tahap evaluasi.

1.7 Ruang Lingkup

Agar trajektori analisis tidak melebar dari sumbu permasalahan utama, ruang lingkup penelitian ini dibatasi sebagai berikut:

1. **Perangkat Keras Uji.** Seluruh proses inferensi AI dipusatkan pada satu smartphone kelas menengah, yaitu Tecno Pova 5 yang ditenagai SoC MediaTek Helio G99 (arsitektur ARM big.LITTLE), RAM LPDDR4x 8 GB, dan ROM UFS 2.2 256 GB.
2. **Lingkungan Eksekusi.** Lingkungan komputasi dikerahkan di atas Android 13 melalui aplikasi emulator terminal non-root Termux, dengan kompilasi mandiri `llama.cpp` agar instruksi CPU ARM dapat dieksploitasi secara natif.
3. **Model Uji.** Penelitian menguji dua SLM berbobot ringan, yaitu **LFM 2.5 (1,2 miliar parameter)** sebagai objek uji utama dan **Qwen 3.5 (2 miliar parameter)** sebagai pembanding stress-test.
4. **Metode Kompresi.** Fokus PTQ dibatasi pada format GGUF presisi campuran (k-quants) yang diturunkan secara gradual melintasi rentang 3-bit hingga 5-bit, yakni **Q3_K_M**, **Q4_K_M**, dan **Q5_K_M**, dengan FP16 sebagai baseline.
5. **Metrik Evaluasi.** Metrik dibatasi pada (a) ukuran berkas, (b) peak RAM, (c) Prompt dan Generation Speed dalam TPS, (d) Perplexity WikiText-2, serta (e) akurasi MMLU, GSM8K, dan HumanEval—masing-masing dibatasi 100 sampel per benchmark.

1.8 Hipotesis

Hipotesis utama yang akan dibuktikan keabsahannya pada penelitian ini adalah:

H1: Implementasi PTQ format GGUF presisi campuran pada rentang 3-bit hingga 5-bit akan secara progresif mereduksi ukuran berkas dan konsumsi RAM SLM secara drastis, sehingga arsitektur SLM dapat dimuat secara stabil ke dalam RAM 8 GB Android tanpa memicu Force Close (OOM Killed). Reduksi bandwidth memori ini sekaligus akan meningkatkan Tokens per Second (TPS) pada CPU ARM secara berlipat ganda jika dibandingkan baseline FP16. Sebaliknya, kompromi degradasi kualitas yang muncul akibat pemotongan presisi diprediksi bersifat minor pada varian Q5_K_M dan Q4_K_M (kenaikan Perplexity di bawah 1 poin dengan rata-rata penurunan akurasi di bawah 5%), namun akan menjadi signifikan pada varian Q3_K_M—khususnya pada dimensi nalar matematis (GSM8K) dan logika pemrograman (HumanEval)—sehingga **Q4_K_M diperkirakan menjadi titik keseimbangan (sweet spot) operasional yang paling optimal** untuk perangkat Android berkapasitas RAM 8 GB.

BAB II — LANDASAN TEORI

2.1 Tinjauan Pustaka

Bab ini memaparkan konsep-konsep fundamental dan rujukan literatur terkait kecerdasan buatan, model bahasa, keterbatasan perangkat keras, serta teknik optimasi memori komputasi yang menjadi landasan teoritis bagi penelitian ini.

2.1.1 Natural Language Processing (NLP) dan Pergeseran ke Edge Computing

Natural Language Processing (NLP) merupakan cabang ilmu kecerdasan buatan yang memungkinkan mesin mengurai, memahami, dan membangkitkan bahasa alami manusia secara kontekstual. Evolusi NLP terus berakselerasi seiring meluasnya implementasi algoritma Deep Learning. Salah satu contoh integrasi NLP pada aplikasi riil di ranah industri lokal adalah pengembangan asisten chatbot kesehatan interaktif berbasis kecerdasan buatan, yang terbukti meningkatkan efisiensi operasional dan kualitas pelayanan rumah sakit serta menjadi kanal konsultasi real-time yang dapat diandalkan oleh masyarakat (Ahmad & Safudin, 2024).

Namun, pengolahan bahasa yang canggih sering menuntut kapabilitas komputasi server cloud. Ketergantungan pada komputasi awan menjadi persoalan dalam penanganan kasus yang menuntut kerahasiaan absolut, seperti data diagnosis rekam medis pasien. Sebagai mitigasi risiko keamanan, pengembangan NLP mulai diarahkan pada arsitektur offline atau lokalisasi pemrosesan pada perangkat seluler konsumen (Mobile Edge Computing). Paradigma offline memastikan kelancaran fungsionalitas sistem AI sekaligus menjamin privasi informasi sensitif dari intervensi jaringan internet terbuka (Zhan dkk., 2025).

Untuk memaksimalkan operasi AI di lingkungan gawai berbasis RAM terbatas, pendekatan Edge Intelligence Optimization sangat diperlukan. Konsep ini memformulasikan teknik penyesuaian stack perangkat lunak agar

perangkat Android dengan spesifikasi minim mampu mengeksekusi beban kerja AI tanpa memicu Force Close yang diakibatkan oleh keterbatasan arsitektur memori bawaan (Zhang dkk., 2024). Hierarki sistem Edge Intelligence dapat dilihat pada Gambar 2.2.

2.1.2 Large Language Models (LLM) dan Fleksibilitasnya

Large Language Models (LLM) merujuk pada arsitektur neural network skala masif yang dilatih menggunakan volume data teks dalam triliunan token. Sebagai fondasi dasar, LLaMA merupakan salah satu pelopor open-source foundation language model berskala besar yang dibangun murni menggunakan dataset publik, dengan kapasitas parameter mulai 7 miliar hingga 65 miliar (Touvron dkk., 2023). Fleksibilitas arsitektur LLM bahkan telah dimanfaatkan sebagai agen kognitif untuk otomatisasi penyusunan jaringan nirkabel di kawasan urban cerdas (Sevim & Ibrahim, 2024), yang menegaskan bahwa model bahasa modern berperan layaknya otak virtual universal.

2.1.3 Small Language Models (SLM) dan Limitasi Perangkat Seluler

Sebagai respons atas mahalnya ongkos inferensi LLM raksasa, para peneliti berinovasi menciptakan Small Language Models (SLM). Arsitektur SLM menyuguhkan desain jaringan parameter yang jauh lebih ramping (umumnya 1–7 miliar parameter) namun sanggup mempertahankan kompetensi analitis yang memadai. Keringkasan arsitektur SLM menjadikannya primadona untuk disematkan langsung ke dalam smartphone. Namun tantangan utamanya adalah arsitektur shared memory: RAM 8 GB pada Android harus dibagi untuk OS, antarmuka layar, dan aplikasi latar belakang. Apabila SLM dimuat penuh dan ukurannya melebihi ruang yang tersisa, Out of Memory Killer akan menghentikan paksa (Force Close) proses AI demi menyelamatkan sistem dari freeze.

2.1.4 Arsitektur Dasar Transformer

Di balik kapabilitas LLM maupun SLM terdapat arsitektur Transformer dengan mekanisme Self-Attention yang memungkinkannya membaca seluruh kata dalam satu kalimat secara simultan, lalu menimbang keterikatan makna antar-token secara kontekstual. Kalkulasi bobot atensi antar-token ini melibatkan operasi matriks masif yang dilakukan lapis demi lapis (layer-by-layer), sehingga Transformer secara bawaan sangat rakus memori dan akan menuntut alokasi gigabyte RAM tambahan seiring dengan panjangnya prompt yang diberikan pengguna.


2.1.5 Konsep Kuantisasi, Presisi Campuran (K-Quants), dan Rentang 3-Bit hingga 5-Bit

Kuantisasi (Quantization) adalah algoritma kompresi fundamental yang digunakan untuk merampingkan kebutuhan ruang penyimpanan dan memory footprint. Saat sebuah model AI dilatih, bobot matriks jaringannya direkam dalam floating-point berpresisi tinggi, umumnya 16-bit (FP16). Format murni ini memiliki ketepatan akurasi yang tinggi namun memakan kapasitas RAM secara ekssesif. Kuantisasi menyederhanakan rangkaian pecahan desimal ini menjadi bilangan bulat yang lebih padat (INT5, INT4, atau bahkan INT3) (Dettmers dkk., 2023).

Di dalam ekosistem llama.cpp, teknik kompresi standar pada awalnya memukul rata semua lapisan model menjadi format bit yang sama. Pendekatan ini memiliki kelemahan: rusaknya bobot penting yang menyebabkan AI mudah berhalusinasi. Untuk mengatasi defisit kecerdasan ini, diciptakanlah metode generasi baru bernama **K-Quants** (ditandai huruf "K"). Pendekatan ini menggunakan presisi campuran (mixed-precision): bagian tensor yang menentukan logika utama (seperti output layers) dipertahankan pada presisi yang lebih aman (misalnya 6-bit), sementara bagian model yang sifatnya pelengkap dan memiliki redundansi tinggi ditekan hingga rentang 3-bit hingga 5-bit. Dalam eksplorasi resource-constrained edge, tiga varian k-quants yang lazim dievaluasi secara bertahap (ablation

study) adalah **Q5_K_M** (rata-rata mendekati 5-bit), **Q4_K_M** (mendekati 4-bit), dan **Q3_K_M** (mendekati 3-bit). Pencarian sweet spot menjadi krusial: kompresi yang kurang padat (>5 -bit) tidak cukup menekan RAM 8 GB, namun kompresi yang terlalu agresif (≤ 3 -bit) berisiko menyebabkan kerusakan kognitif total. Alur transformasi dari FP16 menuju varian $Q^*_K_M$ diilustrasikan pada Gambar 2.1.


Skema Post-Training Quantization GGUF K-Quants (LFM 2.5)



Gambar 2.1 Skema Post-Training Quantization GGUF K-Quants (LFM 2.5).
Sumber: olahan penulis.

2.1.6 Karakteristik Inferensi Mobile: Limitasi CPU dan Bandwidth Memori

Pada arsitektur System-on-Chip (SoC) ARM big.LITTLE, kecepatan inferensi model AI tunduk pada dua hukum komputasi. Pertama, limitasi Memory Bandwidth: inti CPU mungkin sanggup berhitung cepat, namun aliran data parameter SLM kerap memacetkan jalur transfer RAM. Ketika model FP16 dikuantisasi ke 5-bit hingga 3-bit, berkas model menjadi sangat ringan sehingga kemacetan transfer data dari RAM ke CPU ARM terurai. Inilah fondasi argumen mengapa perampingan memori berkorelasi langsung dengan peningkatan Tokens per Second (TPS).



Gambar 2.2 Hierarki Edge Intelligence untuk inferensi SLM. Sumber: olahan penulis berdasarkan (Zhang dkk., 2024).

2.1.7 Format File GGUF (GPT-Generated Unified Format)

GGUF adalah format biner komprehensif yang dirancang spesifik untuk membungkus arsitektur neural network AI generatif dalam satu berkas tertutup. Diciptakan sebagai evolusi dari GGML, GGUF mampu menampung seluruh parameter identitas model beserta metadata-nya. Format ini esensial bagi ekosistem Linux Android (Termux) karena strukturnya dioptimalkan untuk mendistribusikan beban komputasi ke arsitektur CPU dan bersahabat dengan berbagai skema kompresi presisi campuran (K-Quants).

2.1.8 Framework Inferensi llama.cpp di Android

Untuk perangkat konsumen ringan, dunia komputasi Machine Learning sangat bergantung pada llama.cpp. Berbeda dengan framework berbasis Python (PyTorch/TensorFlow) yang menuntut adanya overhead pustaka besar, llama.cpp ditulis dalam C/C++ secara bare-metal. Struktur transparan ini memungkinkannya untuk dikompilasi secara manual agar

sesuai dengan instruksi CPU ARM pada Android, sehingga gawai dapat menjalankan beban kalkulasi Transformer layaknya mesin server (Ray & Pradhan, 2026).

2.1.9 Tantangan Gangguan Matematis (Perturbation)

Pemotongan presisi bobot dari pecahan desimal berukuran gigabyte menjadi angka bulat yang sempit selalu menyisakan efek negatif. Dalam kajian kuantisasi, dampak simplifikasi numerik ini disebut sebagai *perturbation*. Kendala tersulit adalah keberadaan nilai pencilan (*outliers*) yang tidak terprediksi—nilai-nilai ini rentan tersapu saat sistem membulatkan ke integer 3-bit hingga 5-bit terdekat. Hilangnya tumpuan *outliers* inilah yang sering menumpulkan parameter atensi AI dan menyebabkan model berhalusinasi atau menghasilkan jawaban kosong (Gong dkk., 2024). Oleh karena itu, mengevaluasi titik batas kerusakan kompresi (*degradation*) memegang peranan krusial.

2.1.10 Metrik Evaluasi Performa Edge Computing

Kelayakan operasional SLM di Android (Mobile Edge) dievaluasi melalui rasio efisiensi perangkat keras (Jin dkk., 2024). Dua variabel pengamatan esensial mencakup:

- a. **System Memory Usage** (Konsumsi RAM Sistem). Indikator primer untuk mengukur jumlah absolut RAM yang termakan model saat dimuat. Variabel ini wajib dijaga pada batas yang aman (idealnya 1–3 GB) agar OS Android tidak memicu OOM Killer.
- b. **Tokens per Second (TPS)**. Tolok ukur dinamis untuk mengukur laju pemrosesan prompt per detik (Prompt Processing) dan laju ekstraksi karakter per detik (Generation).

2.1.11 Standar Pengujian Kognitif dan Linguistik

Untuk memvalidasi bahwa pengorbanan memori tidak menghasilkan model “tuli atau bisu”, diperlukan tes validasi standar:

- a. **Perplexity (PPL)**. Penilaian dasar kelugasan sintaksis. Semakin rendah PPL, semakin rasional dan natural rangkaian kalimat yang dihasilkan model.
- b. **MMLU** (Massive Multitask Language Understanding). Dataset pengujian wawasan intelektual komprehensif (sejarah, sains, hingga sosiologi) untuk melacak defisit memori faktual pasca-kompresi.
- c. **GSM8K** (Grade School Math 8K). Tes nalar matematika sekolah dasar, digunakan untuk membongkar kerusakan logika kalkulasi akibat pemotongan presisi.
- d. **HumanEval**. Pengujian fungsional logika pemrograman (Python) untuk menakar tingkat kerusakan sintaks model.

2.2 Penelitian Terkait

Demi menempatkan keaslian gagasan penelitian ini dalam lanskap literatur yang relevan, peneliti merujuk pada konstruksi pemikiran dari berbagai studi pilar sebelumnya yang mengedepankan telaah teknis implementasi AI pada ekosistem memori terbatas.

Troboan konseptual efisiensi krisis memori diperkenalkan secara revolusioner oleh Dettmers dkk. (2023) melalui mekanisme kompresi **QLoRA**. Studi ini menjustifikasi secara empiris bahwa pemaksaan struktur bobot dari skala besar ke wadah presisi 4-bit (NF4) sanggup mereduksi footprint hingga sepertiganya, sembari menghindarkan sistem dari Out of Memory tanpa mengebiri utilitas 16-bit asli arsitektur dasar. Argumen efisiensi ini dikukuhkan oleh GPTQ (Frantar dkk., 2023) dan AWQ (Lin dkk., 2023), yang membuktikan bahwa PTQ dengan fokus pada perlindungan salient weights sangat cocok dan stabil bila dibebankan pada SoC seluler.

Akan tetapi, di balik efisiensi memori tersebut terdapat jejak reduksi kualitas kognitif. Studi ekstensif Gong dkk. (2024) dengan lensa perturbation membedah kenyataan bahwa simplifikasi paksa bobot menjadi integer terkompresi sering kali membantai outliers, menginduksi rusaknya pemahaman linguistik AI (ditandai memburuknya Perplexity).

Terlepas dari risiko cacat penalaran, urgensi lokalisasi AI generatif di perangkat mandiri makin tak terbendung. Hal ini dipantik oleh kerentanan latensi dan bandwidth komputasi awan di kawasan urban (Sevim & Ibrahim, 2024). Melalui tinjauan medis, Zhan dkk. (2025) menegaskan bahwa instansi yang berhubungan dengan kerahasiaan data tidak boleh menyerahkan pemrosesan teks ke layanan Cloud API. Kebutuhan asisten cerdas instan, seperti chatbot RS Brawijaya (Ahmad & Safudin, 2024), merupakan manifestasi valid akan urgensi AI lokal.

Demi menstrukturkan matriks pengujian SLM secara objektif, penulis merujuk pada metodologi evaluasi gubahan Jin dkk. (Jin dkk., 2024) dan arsitektur pengujian latensi dari Zhang dkk. (Zhang dkk., 2024). Kedua referensi tersebut menegaskan bahwa kualitas LLM tidak cukup dinilai dari rasio kebenaran, melainkan harus dipadukan dengan skor Perplexity dan TPS. Sebagai klimaks landasan studi terapan, riset observasional Ray dan Pradhan (Ray & Pradhan, 2026) digunakan sebagai pijakan validasi: pengujian PTQ GGUF di atas C++ (`llama.cpp`) pada Raspberry Pi RAM 8 GB membuktikan TPS yang stabil. Tesis empiris ini dipadukan dengan keunggulan arsitektur model lokal seperti Qwen (Nurohim dkk., 2025) dan LLaMA (Touvron dkk., 2023), yang menjadi konfirmasi bahwa komputasi AI offline di atas Android dengan RAM setara merupakan keniscayaan terapan yang krusial untuk dieksplorasi.

Pemaparan ringkas 12 penelitian pilar yang mendasari riset ini disajikan pada Tabel 2.1.

Tabel 2.1 Matriks Perbandingan State of the Art

No	Penulis & Tahun	Judul Penelitian	Metode & Fokus	Hasil Temuan	Kesesuaian (Gap)
1	Dettmers dkk. (2023)	QLoRA: Efficient Finetuning of Quantized LLMs	Kompresi presisi 4-bit (NF4).	Pemadatan 4-bit terbukti mencegah OOM tanpa merusak fungsi 16-bit asli.	Dasar kom-parasi efisiensi RAM dan footprint antar presisi.
2	Gong dkk. (2024)	What Makes Quantization for LLMs Hard? An Empirical Study	Analisis matematis kerentanan kuantisasi LLM terhadap outliers.	Pembulatan outliers berisiko merusak kualitas teks AI.	Instrumen analisis penyebab turunnya skor Perplexity.
3	Zhan dkk. (2025)	Quantized LLMs in Biomedical NLP	Pengujian AI lokal pada ruang privasi tinggi (medis).	AI offline wajib menjaga privasi; kuantisasi sukses menekan jejak RAM.	Fondasi urgensi inferensi AI lokal tanpa Cloud API.

No	Penulis & Tahun	Judul Penelitian	Metode & Fokus	Hasil Temuan	Kesesuaian (Gap)
4	Jin dkk. (2024)	A Comprehensive Evaluation of Quantization Strategies for LLMs	Evaluasi holistik kuantisasi: kapasitas, kelugasan, efisiensi.	Penentuan PPL dan beban RAM sebagai standar ukuran layanan pasca-kuantisasi.	Diadopsi sebagai rancangan matriks metodologi evaluasi.
5	Ray & Pradhan (2026)	Performance Analysis of Localised LLMs in Resource-Constrained Edge	Eksperimen SLM via llama.cpp pada RAM terbatas.	LLM GGUF dapat dieksekusi stabil pada ARM (Raspberry Pi 8 GB).	Kerangka landasan implementasi llama.cpp di SoC ARM Android (Termux).

No	Penulis & Tahun	Judul Penelitian	Metode & Fokus	Hasil Temuan	Kesesuaian (Gap)
6	Frantar dkk. (2023)	GPTQ: Accurate Post-Training Quantization	Kompresi one-shot weight quantization (PTQ).	GPTQ memadatkan model menjadi 3-4 bit dengan degradasi minim.	Landasan algoritma; menjelaskan mengapa Q4 dipilih untuk Android.
7	Lin dkk. (2023)	AWQ: Activation-Aware Weight Quantization	Kuantisasi on-device berbasis aktivasi untuk meminimalkan error 1% bobot penting.	Perlindungan salient weights drastis mengurangi error.	Memperkuat argumen kecocokan PTQ untuk on-device deployment.
8	Zhang dkk. (2024)	Edge Intelligence Optimization for LLM Inference with Batching and Quantization	Optimasi throughput eksekusi LLM di edge.	Optimasi memori lokal memaksimalkan TPS dan memangkas latensi.	Rujukan utama evaluasi TPS di CPU ARM.

No	Penulis & Tahun	Judul Penelitian	Metode & Fokus	Hasil Temuan	Kesesuaian (Gap)
9	Touvron dkk. (2023)	LLaMA: Open and Efficient Foundation Language Models	Pengenalan arsitektur foundation models yang efisien dan terbuka.	Model parameter kecil terlatih banyak token mampu mengungguli GPT-3 (175B).	Literatur arsitektur dasar Transformer LFM/SLM yang dieksekusi di Termux.
10	Sevim dkk. (2024)	LLMs Assisted Wireless Network Deployment in Urban Settings	Evaluasi LLM di ekosistem urban dengan kendala bandwidth.	LLM berbasis cloud sangat bergantungan pada kestabilan internet.	Mempertegas urgensi desentralisasi ke Mobile Edge Computing.

No	Penulis & Tahun	Judul Penelitian	Metode & Fokus	Hasil Temuan	Kesesuaian (Gap)
11	Nurohim dkk. (2025)	Analisis Komparatif LLM DeepSeek dan Qwen dalam Klasifikasi Sentimen	Komparasi SLM open-source pada bahasa lokal (Indonesia).	Qwen memiliki kemampuan bahasa Indone-sia yang akurat.	Justifikasi mengapa Qwen 3.5 layak dipilih untuk dievaluasi di Android.
12	Ahmad & Safudin (2024)	Pengembangan Chatbot AI LLM untuk Layanan Informasi RS Brawijaya	Implementasi asisten AI lokal untuk respons real-time.	Sistem respons cerdas instan meningkatkan kepuasan pelayanan.	Representasi end-goal riset: TPS di HP berguna untuk merakit asisten pintar.

2.3 Tinjauan Objek Penelitian

Objek penelitian dibagi menjadi dua kategori fundamental: ekosistem perangkat keras/perangkat lunak Android, dan spesifikasi arsitektur Small Language Model yang diuji.

2.3.1 Ekosistem Uji Keras: Tecno Pova 5 dengan Termux

Objek operasional dibatasi pada satu smartphone kelas reguler, yaitu Tecno Pova 5. Perangkat ini ditenagai SoC MediaTek Helio G99 berbasis ARM,

dengan RAM sistem 8 GB. Mengingat status gawai non-rooted (bawaan pabrik tanpa akses root), lingkungan pengujian virtual dibangun di atas aplikasi emulator Linux portabel **Termux**. Melalui kompilasi mandiri di Termux inilah `llama.cpp` di-build ulang dalam konfigurasi C/C++ serupa lingkungan server, agar instruksi CPU ARM dapat dieksekusi secara optimal.

2.3.2 Objek Arsitektur SLM: LFM 2.5 (1,2B) dan Qwen 3.5 (2B)

Riset komparatif ini menggunakan dua model SLM. Objek uji utama adalah **LFM 2.5** dengan densitas parameter 1,2 miliar. Struktur mikronya yang dirancang efisien menjadikannya kandidat menjanjikan untuk dikompresi bertahap pada rentang 3-bit hingga 5-bit guna menekan konsumsi RAM. Versi mentah FP16-nya akan dibandingkan dengan tiga varian K-Quants (Q5_K_M, Q4_K_M, dan Q3_K_M) pada fase ablation study. Sebagai pembanding stress-test, digunakan arsitektur **Qwen 3.5 (2 miliar parameter)**—pilihan ini berfungsi sebagai instrumen pengukur batas toleransi ekstrem sistem, sekaligus mendemonstrasikan fenomena scaling laws (kemampuan model bertahan) ketika ekosistem Android RAM 8 GB dan Helio G99 dipaksa menjalankan beban arsitektur di atas 2 miliar parameter pasca-kuantisasi.

BAB III — METODOLOGI PENELITIAN

3.1 Tahapan Penelitian


Dalam melaksanakan penelitian berbasis komputasi eksperimental pada perangkat seluler, tahapan kerja disusun secara sistematis agar proses pengujian tetap berfokus pada tujuan awal dan menghasilkan data empiris yang valid. Mengacu pada kerangka evaluasi kuantisasi holistik (kapasitas, kelugasan, efisiensi) (Jin dkk., 2024), alur penelitian ini terbagi menjadi **lima tahapan utama** sebagai berikut.

1. **Studi Pendahuluan dan Perumusan Masalah.** Tahap awal mencakup kajian pustaka komprehensif mengenai Mobile Edge Computing (Zhang dkk., 2024; Sevim & Ibrahim, 2024) dan Post-Training Quantization (Dettmers dkk., 2023; Frantar dkk., 2023). Urgensi lokalisasi pemrosesan AI secara offline ditetapkan sebagai landasan utama (Zhan dkk., 2025), sementara batasan kapasitas RAM 8 GB pada Android difokuskan sebagai bottleneck arsitektur. Tahap ini dilanjutkan dengan perumusan hipotesis terkait solusi kompresi presisi campuran (Lin dkk., 2023).
2. **Persiapan Lingkungan Komputasi (Environment Setup).** Testbed dikonfigurasi di atas Android dengan emulator terminal non-root Termux. Tahap ini meliputi pembaruan paket dasar (pkg update) serta instalasi toolchain C++ (clang, cmake, make). Repositori llama.cpp selanjutnya di-clone dan dikompilasi secara manual dengan opsi native ARM build, sebagaimana pendekatan yang telah divalidasi pada perangkat ARM serupa (Ray & Pradhan, 2026).
3. **Persiapan Objek Model dan Kuantisasi (Ablation Setup).** Berkas FP16 untuk LFM 2.5 (1,2B) dan Qwen 3.5 (2B) disiapkan (Touvron dkk., 2023). Pemilihan Qwen sebagai uji kedua didasarkan pada kompetensi bahasa Indonesia yang telah terbukti (Nurohim dkk., 2025). Untuk mengeksekusi ablation gradasi kompresi, berkas FP16 dikonversi menggunakan utilitas ./llama-quantize di dalam Termux untuk menghasilkan tiga varian k-quants, yakni **Q5_K_M.gguf**,

Q4_K_M.gguf, dan **Q3_K_M.gguf** (Dettmers dkk., 2023).

4. **Eksekusi Eksperimen (System Benchmarking).** Pengujian beban kerja dilakukan melalui CLI Termux. Evaluasi dijalankan sekuensial dari FP16 (variabel kontrol), dilanjutkan Q5, Q4, dan Q3. Pada fase ini, peak RAM dicatat melalui htop, TPS diekstraksi dari log sistem (Zhang dkk., 2024), dan Perplexity dieksekusi melalui `./llama-perplexity` untuk mengidentifikasi perturbation akibat kompresi (Gong dkk., 2024).
5. **Analisis Komparatif dan Penarikan Kesimpulan.** Data mentah dari Termux diekstraksi ke dalam tabulasi matriks. Data dimensi efisiensi (hardware) dan dimensi kognitif (software) dikomparasikan menggunakan kerangka evaluasi tiga dimensi (Jin dkk., 2024) untuk mengidentifikasi titik sweet spot.

Alur tahapan penelitian ini direpresentasikan secara visual pada Gambar 3.1.



Gambar 3.1 Tahapan Penelitian. Sumber: olahan penulis.

3.2 Instrumen Penelitian

Penelitian ini menitikberatkan pada evaluasi kinerja infrastruktur ujung dengan sumber daya terbatas (resource-constrained edge) (Ray & Pradhan, 2026). Instrumen yang digunakan terdiri atas perangkat keras konsumen (off-the-shelf) dan ekosistem perangkat lunak open-source berkinerja tinggi, sebagaimana dirinci pada Tabel 3.1 dan Tabel 3.2.

Tabel 3.1 Spesifikasi Perangkat Keras (Hardware)

Komponen	Spesifikasi	Keterangan
Perangkat	Tecno Pova 5	Smartphone kelas menengah.
SoC	MediaTek Helio G99 (ARM big.LITTLE)	CPU-bound inference.
Memori Utama (RAM)	8 GB LPDDR4x	Shared-memory dengan Host OS — alat ukur sekaligus bottleneck Force Close (Zhang dkk., 2024).
Penyimpanan Internal	UFS 2.2 256 GB	Menampung seluruh variasi berkas .gguf.

Tabel 3.2 Spesifikasi Perangkat Lunak (Software)

Komponen	Versi/Tooling	Keterangan
Sistem Operasi Dasar	Android 13	Lapisan manajemen memori inti (Host OS).

Komponen	Versi/Tooling	Keterangan
Lingkungan Simulasi Terminal	Termux non-root	Menyediakan fondasi paket Linux murni tanpa membuka enkripsi partisi sistem.
Mesin Inferensi	llama.cpp (C/C++ bare-metal)	Dipilih karena dapat dikompilasi natif ke instruksi CPU ARM (Ray & Pradhan, 2026).
Pemantauan Memori	htop interaktif	Menangkap metrik Peak RAM Usage.
Evaluasi Kognitif	./llama-perplexity	Mengkalkulasi degradasi linguistik (PPL) pada dataset WikiText-2 (Gong dkk., 2024).
Evaluasi Akurasi	Skrip kustom (MMLU, GSM8K, HumanEval)	Menjalankan 100 sampel per benchmark melalui CLI llama.cpp.

3.3 Metode Pengumpulan Data

Penelitian terapan ini berfokus pada ekstraksi data komputasional yang objektif (System Logging Benchmarking), tanpa bergantung pada instrumen opini subjektif. Metode pengumpulan data yang diaplikasikan mencakup pengamatan langsung dan studi pustaka.

A. Pengamatan Langsung (Observasi Eksperimental)

Observasi dilakukan melalui system benchmarking logging dengan memantau indikator performa perangkat keras dan perangkat lunak saat SLM mengeksekusi instruksi di dalam Termux. Peneliti mencatat konsumsi RAM absolut (dalam MB/GB) melalui monitor htop pada setiap transisi resolusi kompresi (FP16, Q5_K_M, Q4_K_M, dan Q3_K_M). Selanjutnya, data kuantitatif berupa rasio kecepatan pemrosesan kata atau Tokens per Second (TPS) dan nilai Perplexity disalin secara langsung dari layar log terminal pada detik ketika kalkulasi inferensi dinyatakan selesai oleh sistem (Jin dkk., 2024; Zhang dkk., 2024).

B. Studi Pustaka

Pengumpulan data sekunder dilakukan dengan menghimpun dan memetakan kajian literatur dari jurnal akademik mutakhir (periode 2023–2026) yang membahas PTQ (Dettmers dkk., 2023; Frantar dkk., 2023), arsitektur model bahasa terbuka (Touvron dkk., 2023), teknik kompresi berbasis aktivasi (Lin dkk., 2023), serta fenomena Mobile Edge Computing (Zhang dkk., 2024; Sevim & Ibrahim, 2024). Urgensi lokalisasi pemrosesan AI untuk menjamin privasi data (Zhan dkk., 2025) dan kebutuhan sistem respons cerdas yang instan pada sektor layanan publik (Ahmad & Safudin, 2024) turut memperkuat justifikasi eksperimental penelitian ini. Studi kepustakaan ini menjadi landasan dalam penentuan parameter kalibrasi pengujian, sehingga skenario stress-test yang diterapkan sejalan dengan standar evaluasi performa AI pada perangkat dengan sumber daya terbatas (Ray & Pradhan, 2026).

3.4 Metode Analisis Data

Data metrik mentah (raw data log) yang diekstraksi dari perangkat uji selanjutnya diolah menggunakan **Analisis Komparatif Bertingkat (Ablation Study)**. Metode ini mengkaji selisih kinerja (performance gap) antara model presisi murni (FP16 sebagai baseline) dengan level kompresi

di bawahnya, yaitu Q5_K_M, Q4_K_M, dan Q3_K_M (Dettmers dkk., 2023; Frantar dkk., 2023).

Berlandaskan **kerangka evaluasi tiga dimensi** (Three-Dimensional Evaluation Framework) (Jin dkk., 2024), data diolah untuk memproduksi dua matriks kalkulasi turunan:

1. **Analisis Efisiensi Perangkat Keras (Infrastruktur).** Data peak RAM diolah ke dalam persentase efisiensi guna mengevaluasi keamanan sistem operasi terhadap risiko Force Close (Zhang dkk., 2024). Formula yang digunakan:

$$\text{Reduksi Memori (\%)} = \frac{\text{RAM}_{\text{FP16}} - \text{RAM}_{\text{Kuantisasi}}}{\text{RAM}_{\text{FP16}}} \times 100\%$$

Bagi varian yang FP16-nya gagal dimuat akibat OOM, data dicatat sebagai hardware limit. Selain itu, data waktu pemrosesan dikonversi menjadi TPS (total token dibagi durasi eksekusi dalam detik).

2. **Analisis Fluktuasi Degradasi Kognitif.** Data pergeseran kualitas linguistik yang terekam (skor Perplexity) dianalisis berdasarkan margin pelebarannya (Gong dkk., 2024). PPL bersifat inverse: semakin tinggi PPL pasca-kompresi terhadap baseline, semakin parah degradasi pemahaman model akibat hilangnya outliers (Gong dkk., 2024)—risiko yang perlu dimitigasi melalui pendekatan kompresi berbasis proteksi bobot salient (Lin dkk., 2023).

Data akhir dari matriks efisiensi (RAM dan TPS) selanjutnya dikorelasikan secara grafis dengan matriks kognitif (PPL dan akurasi benchmark). Melalui analisis kuantitatif ini, peneliti menetapkan **titik Sweet Spot**: varian k-quants yang menunjukkan rasionalitas paling tinggi untuk diimplementasikan pada smartphone Android berkapasitas RAM 8 GB (Jin dkk., 2024; Ray & Pradhan, 2026).

BAB IV — HASIL PENELITIAN DAN PEMBAHASAN

4.1 Lingkungan Pengujian dan Skenario

Bab ini menguraikan data hasil pengujian (benchmarking) yang diperoleh melalui eksekusi model AI sesuai skenario yang telah ditetapkan. Penelitian ini menerapkan metode **Host-to-Target Deployment**: fase kompresi bobot arsitektur melalui PTQ dilakukan pada mesin host berspekifikasi tinggi (PC dengan GPU NVIDIA RTX 3060) guna mengoptimalkan kecepatan kalkulasi K-Quants. Berkas hasil kompresi dalam format .gguf selanjutnya dipindahkan ke unit Target Edge Device, yaitu smartphone Android Tecno Pova 5 (SoC MediaTek Helio G99, RAM 8 GB), untuk dieksekusi secara lokal melalui `llama.cpp` pada terminal Termux.

Instrumen komparasi silang (cross-validation) menggunakan dua varian SLM:

- **LFM 2.5 (1,2B)** sebagai representasi arsitektur ultra-ringan.
- **Qwen 3.5 (2B)** sebagai instrumen uji beban memori (stress-test).

Evaluasi dilakukan secara bertingkat dengan membandingkan versi FP16 sebagai variabel kontrol terhadap tiga varian kuantisasi, yakni Q5_K_M, Q4_K_M, dan Q3_K_M.

4.2 Hasil Uji Efisiensi Infrastruktur (Hardware)


Pengujian efisiensi infrastruktur ditujukan untuk mengidentifikasi dampak kuantisasi terhadap reduksi kapasitas penyimpanan fisik (storage), alokasi memori sistem Android (RAM), serta akselerasi kinerja prosesor (TPS).

4.2.1 Reduksi Kapasitas Penyimpanan Fisik (Storage)

Tahap observasi awal berfokus pada pengukuran ukuran aktual berkas model pada penyimpanan internal gawai. Data komparasi ukuran fisik dan persentase reduksinya disajikan pada Tabel 4.1.

Tabel 4.1 Reduksi Ukuran Berkas Model per Varian Kuantisasi

Model Arsitektur	Presisi / Format	Ukuran Berkas	Persentase Reduksi
LFM 2.5 (1,2B)	F16 (Original)	2,2 GB	—
LFM 2.5 (1,2B)	Q5_K_M	805 MB	↓ 63,41%
LFM 2.5 (1,2B)	Q4_K_M	698 MB	↓ 68,27%
LFM 2.5 (1,2B)	Q3_K_M	573 MB	↓ 73,95%
Qwen 3.5 (2B)	F16 (Original)	3,6 GB	—
Qwen 3.5 (2B)	Q5_K_M	1,4 GB	↓ 61,11%
Qwen 3.5 (2B)	Q4_K_M	1,2 GB	↓ 66,67%
Qwen 3.5 (2B)	Q3_K_M	1,1 GB	↓ 69,44%

**Gambar 4.1** Reduksi ukuran berkas model per varian kuantisasi. Sumber: olahan penulis.

Berdasarkan Tabel 4.1, implementasi kuantisasi mampu mereduksi ukuran berkas model secara signifikan melampaui 60%. Pada varian Q3_K_M, ukuran LFM 2.5 berhasil ditekan hingga 573 MB, sementara Qwen 3.5 menyusut menjadi 1,1 GB, sehingga memberikan ketersediaan ruang penyimpanan ROM yang lebih besar pada perangkat.

4.2.2 Konsumsi RAM dan Kecepatan Inferensi (Helio G99)


Pengujian performa komputasi dilakukan secara batch langsung pada perangkat target Tecno Pova 5 melalui script otomatisasi benchmark.sh di Termux. Setiap varian model diuji **tiga kali** (kecuali tiga varian Qwen yang diuji dua kali akibat keterbatasan termal perangkat), dengan jeda cooldown manual 3–5 menit antar model untuk menghindari thermal throttling. Metrik kecepatan baca (Prompt Speed) dan kecepatan produksi teks (Generation Speed) diekstraksi dari keluaran statistik llama-cli, sedangkan konsumsi RAM proses (VmRSS) dan beban CPU dipantau secara periodik (setiap 0,5 detik) dari /proc/<pid>/status menggunakan konfigurasi 6 threads. Hasil agregat (rerata $\pm$ simpangan baku) disajikan pada Tabel 4.2.

Tabel 4.2 Performa Inferensi (Total Waktu, Prompt Speed, Generation Speed, Peak RAM proses, dan CPU Peak) — rerata $\pm$ simpangan baku


					Peak	
Model		Total	Prompt	Gen	RAM	
(Format)	N	Waktu	Speed	Speed	Proses	CPU
		(s)	(t/s)	(t/s)	(MB)	Peak (%)
LFM	3	16,00 $\pm$	33,47 $\pm$	5,57 $\pm$	2.303,47	292,33
2.5		2,83	6,49	0,19	$\pm$ 13,32	$\pm$ 20,04
(F16)						
LFM	3	10,67 $\pm$	35,33 $\pm$	10,63 $\pm$	1.665,28	357,33
2.5		1,70	1,21	0,62	$\pm$ 14,07	$\pm$ 33,81
(Q5_K_M)						
LFM	3	7,33 $\pm$	43,67 $\pm$	13,67 $\pm$	1.452,97	299,33
2.5		0,47	2,38	0,24	$\pm$ 14,15	$\pm$ 19,69
(Q4_K_M)						
LFM	3	14,33 $\pm$	18,27 $\pm$	11,07 $\pm$	911,97	464,00
2.5		1,89	1,82	0,69	$\pm$ 15,08	$\pm$ 6,98
(Q3_K_M)						

					Peak	
		Total	Prompt	Gen	RAM	
Model		Waktu	Speed	Speed	Proses	CPU
(Format)	N	(s)	(t/s)	(t/s)	(MB)	Peak (%)
Qwen 3.5 (F16)	3	310,33 ± 76,27	22,70 ± 1,71	1,87 ± 0,19	3.744,25 ± 8,05	430,33 ± 34,65
Qwen 3.5 (Q5_K_M)	2	181,00 ± 27,00	22,55 ± 0,25	4,60 ± 0,30	2.856,29 ± 0,29	509,00 ± 20,00
Qwen 3.5 (Q4_K_M)	2	297,00 ± 46,00	27,00 ± 2,60	4,95 ± 0,25	2.562,88 ± 0,46	500,50 ± 25,50
Qwen 3.5 (Q3_K_M)	2	187,00 ± 100,00	14,55 ± 0,95	4,25 ± 0,35	1.897,97 ± 0,02	525,00 ± 2,00

Catatan: kolom CPU Peak* (%) mencerminkan beban gabungan terhadap 6 thread yang dialokasikan (skala maksimal teoretis 600%, menggunakan metrik %CPU dari ps).*



Gambar 4.2 Konsumsi Peak RAM proses per varian kuantisasi pada Helio G99 (RAM 8 GB). Error bar menunjukkan $\pm$ satu simpangan baku. Sumber: olahan penulis.



Gambar 4.3 Kecepatan inferensi (Prompt vs Generation) per varian kuantisasi. Error bar menunjukkan $\pm$ satu simpangan baku. Sumber: olahan penulis.

Reduksi RAM proses yang konsisten terlihat pada kedua model: pemuatan Qwen 3.5 FP16 menyentuh 3,74 GB—nyaris 47% dari RAM sistem 8 GB—yang berisiko memicu OOM Killer. Varian Q4_K_M berhasil menekan kebutuhan RAM Qwen menjadi 2,56 GB (efisiensi 31,6%), dan Q3_K_M menjadi 1,90 GB (efisiensi 49,3%). Tren ini sejalan dengan akselerasi Generation Speed: LFM Q4_K_M mencapai $13,67 \pm 0,24$ t/s, atau 2,45 kali lipat baseline FP16 (5,57 t/s), sekaligus menjadi varian dengan total waktu eksekusi paling singkat (7,33 detik) dan beban CPU yang terkontrol di rentang $\sim 299\%$. Sebaliknya, ketiga varian Qwen 3.5 menunjukkan Generation Speed yang seragam rendah pada rentang 1,87–4,95 t/s, yang menggambarkan keterbatasan model berarsitektur reasoning berukuran 2 miliar parameter pada CPU ARM kelas menengah ke bawah (lihat keterbatasan tambahan pada Sub-bab 4.3.3).

4.3 Hasil Uji Degradasi Kognitif (Software / AI)


Evaluasi kognitif bertujuan mengukur dampak kompresi terhadap kecerdasan neural network model menggunakan metrik Perplexity serta serangkaian uji pemahaman akademik.

4.3.1 Evaluasi Perplexity (PPL)

Perplexity digunakan untuk mengukur tingkat ambiguitas model terhadap struktur sintaksis pada dataset WikiText-2. Nilai PPL yang lebih rendah mengindikasikan tingkat pemahaman bahasa yang lebih baik. Hasilnya ditunjukkan pada Tabel 4.3.

Tabel 4.3 Hasil Perplexity (PPL) WikiText-2 per Varian Kuantisasi

Varian Kompresi	PPL LFM 2.5 (1,2B)	PPL Qwen 3.5 (2B)
F16 (baseline)	12,6829	12,7763
Q5_K_M	12,8297	13,0856
Q4_K_M	13,2145	13,3617
Q3_K_M	14,5135	15,2172



Gambar 4.4 Degradasi Perplexity pada dataset WikiText-2. Sumber: olahan penulis.

4.3.2 Evaluasi Akurasi Logika (MMLU, GSM8K, dan HumanEval) serta Kreativitas Bahasa (MT-Bench TTR)

Evaluasi akurasi menggunakan tiga instrumen benchmark kognitif: MMLU (pemahaman umum berbasis pilihan ganda A/B/C/D), GSM8K (nalar matematika dengan jawaban numerik), dan HumanEval (akurasi pemrograman Python dievaluasi melalui unit-test), serta satu instrumen tambahan berupa MT-Bench dengan skor Type-Token Ratio (TTR) yang mengukur keragaman leksikal teks generatif. Masing-masing benchmark mengeksekusi 100 sampel acak dengan suhu sampling deterministik ($\text{temperature}=0$). Eksekusi akurasi dijalankan pada host PC NVIDIA RTX 3060 untuk menghemat waktu evaluasi, sedangkan validasi performa keluaran model identik dengan eksekusi pada perangkat target karena format .gguf yang seragam. Data hasil pengujian disajikan pada Tabel 4.4 dan Tabel 4.5.

Tabel 4.4 Hasil Benchmark Akurasi LFM 2.5 (1,2B)


Benchmark	F16	Q5_K_M	Q4_K_M	Q3_K_M
MMLU (A/B/C/D)	32%	34%	25%	28%
GSM8K (numerik)	58%	55%	50%	40%
HumanEval (kode)	36%	29%	37%	30%
MT-Bench TTR	0,526	0,509	0,468	0,403

Tabel 4.5 Hasil Benchmark Akurasi Qwen 3.5 (2B) *

Benchmark	F16	Q5_K_M	Q4_K_M	Q3_K_M
MMLU (A/B/C/D) *	40%	29%	37%	40%
GSM8K (numerik) **	16%	17%	19%	12%
HumanEval (kode)	52%	47%	40%	25%
MT-Bench TTR	0,546	0,412	0,568	0,521

* Qwen 3.5 (2B) merupakan model dengan arsitektur reasoning (memproduksi blok `<think>...</think>` sebagai jejak penalaran sebelum jawaban

final). Skor akurasi yang dilaporkan menggunakan parser berlapis yaitu pencocokan ketat (####<num>, \boxed{...}, final answer) dengan fallback pada kandidat angka/huruf terakhir setelah eliminasi blok <think>. ** Skor GSM8K Qwen sangat rendah karena 60–80% keluaran model tidak menyelesaikan penalaran dalam anggaran 200 token yang ditetapkan (strict_miss tinggi); detail keterbatasan ini dijelaskan pada Sub-bab 4.3.3.



Gambar 4.5 Hasil benchmark akurasi (MMLU, GSM8K, HumanEval) untuk kedua model. Sumber: olahan penulis.

Berdasarkan Tabel 4.4, LFM 2.5 (1,2B) menunjukkan stabilitas akurasi yang relatif konsisten antar varian: penurunan paling tajam terlihat pada GSM8K (58% → 40% pada Q3_K_M, selisih 18 poin), sementara MMLU justru memperlihatkan fluktuasi non-monoton yang masih berada di rentang sekitar 28–34%, dan HumanEval relatif stabil di kisaran 29–37%. Skor MT-Bench TTR menurun seiring tingkat kuantisasi (0,526 → 0,403), mengindikasikan terjadinya pengurangan keragaman leksikal pada keluaran teks ketika presisi bobot semakin agresif. Pada Tabel 4.5, hasil Qwen 3.5 (2B) menunjukkan profil yang sangat berbeda: HumanEval mengalami penurunan progresif (52% → 25% pada Q3_K_M), sementara skor GSM8K terlihat sangat rendah secara seragam (12–19%) bukan akibat kerusakan logika model, melainkan keterbatasan instrumen evaluasi terhadap reasoning model yang diuraikan pada sub-bab berikut.

4.3.3 Keterbatasan Evaluasi Akurasi pada Reasoning Model (Qwen 3.5)

Qwen 3.5 (2B) yang digunakan pada penelitian ini termasuk dalam kategori reasoning model: alih-alih langsung menjawab, model menghasilkan blok penalaran rantai-pikiran (chain-of-thought) yang ditandai oleh penanda khusus `<think> ... </think>` sebelum jawaban final. Karakteristik arsitektural ini menimbulkan tiga konsekuensi metodologis yang membatasi validitas perbandingan akurasi pada Tabel 4.5.

1. **Anggaran token yang terbatas (200 token) sering habis pada blok `<think>`.** Pada eksekusi GSM8K, ditemukan 60–80% respons (strict_miss 63 hingga 80 dari 100 sampel) yang berakhir tanpa pernah memproduksi penanda jawaban final (####<num>, \boxed{...}, atau frasa final answer) karena anggaran token tuntas sebelum penalaran rampung.
2. **Parser fallback tidak ekuivalen dengan jawaban benar.** Setelah pencocokan ketat gagal, fallback mengambil kandidat angka terakhir pada teks. Pada keluaran reasoning yang masih dalam tahap analisis, angka terakhir merupakan langkah-langkah aritmetika pertengahan, bukan kesimpulan; akibatnya fallback_hit mencapai 60–80 tetapi proporsi yang sesungguhnya benar tetap rendah ($\leq 19\%$).
3. **Variansi antar run tinggi.** Pengulangan terhadap kombinasi (Qwen 3.5 F16, GSM8K) menghasilkan skor 21%, 65%, dan 16% di tiga run terpisah pada konfigurasi parameter yang sama. Variansi ini bukan disebabkan ketidakdeterministikan model (suhu sampling sudah disetel 0), melainkan oleh interaksi antara panjang penalaran, ambang penghentian dini (early stopping) berdasarkan pencocokan frasa final answer, dan perubahan kecil pada prompt template.

Upaya mitigasi telah dilakukan dengan menaikkan anggaran token menjadi 1024 dan menambahkan jendela konteks 2048 token, namun pola strict_miss tinggi pada GSM8K tetap muncul karena rata-rata panjang penalaran Qwen 3.5 untuk soal kelas SD/SMP melampaui jendela tersebut.

Oleh karena itu, skor akurasi Qwen 3.5 pada Tabel 4.5 (khususnya kolom GSM8K dengan tanda **) dilaporkan sebagai lower bound dan **tidak boleh diinterpretasikan sebagai kemampuan inheren model**. Konsekuensi dari keterbatasan ini diuraikan kembali pada BAB V Sub-bab 5.2 (Keterbatasan Penelitian), dengan rekomendasi penelitian lanjutan untuk memisahkan prompt reasoning-mode dan instruct-mode serta mengevaluasi dengan instrumen yang sadar-format penalaran (misalnya MATH dataset dengan answer extractor yang ekuivalen dengan reasoning trace).

4.4 Pembahasan Analisis Komparatif

Sub-bab ini membedah signifikansi data hasil pengujian melalui tinjauan teoritis arsitektur Edge Intelligence dan hukum ketahanan kompresi (scaling laws).

4.4.1 Efisiensi RAM dan Peningkatan Generation Speed

Hasil pengujian mengonfirmasi bahwa metode PTQ efektif dalam mengatasi kendala shared-memory pada perangkat berkapasitas RAM 8 GB. Pemuatan model FP16 pada Qwen 3.5 menyerap hampir 47% kapasitas RAM sistem (3,74 GB), yang berisiko memicu OOM Killer oleh sistem operasi Android. Intervensi Q4_K_M mampu mereduksi penggunaan RAM Qwen menjadi 2,56 GB (efisiensi 31,6%), sedangkan Q3_K_M menekannya menjadi 1,90 GB (efisiensi 49,3%), sehingga menjamin stabilitas operasional latar belakang sistem. Penurunan beban bandwidth data dari RAM ke CPU berimplikasi pada peningkatan Generation Speed untuk LFM 2.5, yang melonjak dari 5,57 t/s pada FP16 menjadi 13,67 t/s pada Q4_K_M—akselerasi 2,45 kali lipat dibanding versi murninya. Hal ini membuktikan dalil Memory-Bound (Zhang dkk., 2024), di mana kinerja inti prosesor sering terhambat oleh besarnya volume data pada antrean memori. Konsisten dengan dalil ini, total waktu eksekusi LFM Q4_K_M juga merupakan yang tersingkat ($7,33 \pm 0,47$ detik), atau 2,18 kali lebih cepat dibanding FP16 (16 detik).

4.4.2 Anomali Kecepatan Baca (Prompt Speed) pada Varian Q3_K_M

Data pada Tabel 4.2 menunjukkan adanya anomali pada varian Q3_K_M LFM 2.5. Secara teoritis, model dengan kebutuhan RAM terendah seharusnya memiliki performa tercepat; namun, Prompt Speed LFM Q3_K_M justru anjlok ke $18,27 \pm 1,82$ t/s, lebih rendah dibanding Q4_K_M ($43,67 \pm 2,38$ t/s) maupun Q5_K_M ($35,33 \pm 1,21$ t/s). Pola serupa juga teramati pada Qwen 3.5: Q3_K_M ($14,55$ t/s) lebih lambat dibanding Q4_K_M ($27,00$ t/s) dan Q5_K_M ($22,55$ t/s). Fenomena ini dianalisis sebagai konsekuensi arsitektur CPU ARM: proses unpacking data 4-bit atau 5-bit bersifat efisien karena strukturnya simetris bagi register CPU. Sebaliknya, format 3-bit yang bersifat ganjil memaksa set instruksi CPU melakukan operasi bit-shifting tambahan yang kompleks, sehingga menyebabkan sumbatan komputasi (bottleneck) pada fase pre-fill dan memperpanjang durasi eksekusi total. Beban CPU peak yang teramati pada varian Q3_K_M kedua model juga menjadi yang tertinggi (LFM 464%; Qwen 525%), mengindikasikan saturasi thread yang lebih tinggi pada operasi dequantization.

4.4.3 Dampak Distorsi terhadap Nalar Matematika dan Logika Pemrograman


Penurunan performa varian Q3_K_M meluas hingga dimensi kognitif. Skor Perplexity yang melampaui ambang batas toleransi (14,5–15,2) mengindikasikan adanya kerusakan pada struktur nalar model. Hal ini diperkuat oleh anjloknya akurasi pada benchmark GSM8K LFM 2.5 ($58 \rightarrow 40\%$, selisih 18 poin) dan HumanEval Qwen 3.5 ($52 \rightarrow 25\%$, selisih 27 poin). Penurunan tajam ini disebabkan oleh disrupsi kuantisasi ekstrem yang mengeliminasi nilai-nilai pencilan (outliers) pada matriks bobot (Gong dkk., 2024). Berbeda dengan redundansi pada bahasa naratif, logika matematis dan pemrograman bersifat eksak; sehingga pemotongan presisi yang terlalu agresif secara otomatis meruntuhkan fondasi logika fungsional kecerdasan buatan tersebut. Skor MT-Bench TTR pada LFM 2.5 juga menurun secara monoton dari 0,526 (F16) ke 0,403 (Q3_K_M),

memperkuat indikasi adanya penyempitan distribusi leksikal sebagai akibat dari hilangnya presisi pada bobot pasca-kuantisasi.

4.4.4 Penetapan Titik Keseimbangan Optimal (Sweet Spot)

Melalui sintesis antara matrikulasi performa fisik dan kualitas kognitif, penelitian ini menetapkan varian **Q4_K_M** sebagai sweet spot untuk implementasi Mobile Edge AI. Varian ini mengoptimalkan penggunaan RAM pada tingkat yang aman bagi perangkat berkapasitas 8 GB, sambil tetap mempertahankan Prompt Speed (43,67 t/s pada LFM) dan Generation Speed (13,67 t/s pada LFM) pada level tertinggi di antara seluruh varian kuantisasi yang diuji. Efisiensi ini dicapai dengan margin kesalahan rata-rata akurasi LFM yang relatif terkontrol (penurunan GSM8K 8 poin dari baseline 58%, sekaligus gain pada HumanEval +1 poin) serta kenaikan Perplexity yang masih di bawah 0,6 poin terhadap baseline FP16. Visualisasi trade-off multi-dimensi disajikan pada Gambar 4.6.

Trade-off Multi-Dimensi LFM 2.5 (1,2B) per Varian Kuantisasi



Gambar 4.6 Diagram radar trade-off multi-dimensi LFM 2.5 (1,2B) per varian kuantisasi. Sumber: olahan penulis.

BAB V — PENUTUP

5.1 Kesimpulan

Berdasarkan serangkaian eksperimen mengenai optimasi arsitektur Small Language Model pada ekosistem Mobile Edge Computing berbasis Android, dapat ditarik beberapa kesimpulan utama sebagai jawaban atas rumusan masalah penelitian, yaitu:

1. **Efektivitas Kuantisasi dalam Mitigasi Limitasi Memori.** Implementasi PTQ dengan format GGUF terbukti secara empiris mampu mengatasi kendala shared-memory pada Android kelas menengah. Penggunaan FP16 dengan parameter 2 miliar menyebabkan dominasi penggunaan RAM hingga 3,66 GB—berisiko tinggi memicu Force Close. Melalui reduksi presisi ke Q4_K_M dan Q3_K_M, beban memori dikompresi melampaui 60% (storage) dan 30-48% (RAM), sehingga menjamin stabilitas operasional perangkat.
2. **Optimalisasi Kecepatan Inferensi dan Anomali Arsitektur ARM.** Reduksi ukuran berkas berbanding lurus dengan peningkatan Generation Speed (Q4 LFM: $2,75\times$ baseline). Namun, penelitian ini mengidentifikasi adanya anomali pada CPU ARM, di mana Q3_K_M mengalami degradasi signifikan pada Prompt Speed karena kompleksitas unpacking susunan bit ganjil. Hal ini membuktikan bahwa ukuran berkas yang lebih kecil tidak selalu menghasilkan latensi yang lebih rendah pada arsitektur ARM.
3. **Integritas Kognitif dan Titik Keseimbangan Operasional (Sweet Spot).** Kompresi ekstrem pada Q3_K_M menyebabkan degradasi kualitas kognitif yang signifikan, ditandai dengan anjloknya akurasi GSM8K dan HumanEval serta pelebaran Perplexity. Penurunan ini disebabkan oleh hilangnya outliers pada matriks bobot yang esensial bagi nalar matematis. Dengan demikian, **Q4_K_M ditetapkan sebagai sweet spot operasional** karena mampu memberikan efisiensi penggunaan RAM dan kecepatan inferensi yang optimal tanpa mengorbankan integritas nalar dan logika fungsional model.

5.2 Keterbatasan Penelitian

Guna menjaga objektivitas pelaporan ilmiah, penulis menggariskan empat keterbatasan utama yang melekat pada desain eksperimen ini, sebagai berikut:

1. **Lingkup Perangkat Tunggal.** Seluruh metrik performa fisik (TPS, peak RAM proses, beban CPU, dan total waktu eksekusi) diukur pada satu unit perangkat Tecno Pova 5 (SoC MediaTek Helio G99, RAM 8 GB) di lingkungan Termux. Hasil ini belum mewakili variasi karakteristik termal, governor CPU, atau skema power management pada SoC lain (Snapdragon 6/7/8 gen, Dimensity, atau Tensor) maupun pada perangkat tablet/laptop berbasis ARM.
2. **Ukuran Sampel Benchmark Akurasi.** Evaluasi MMLU, GSM8K, dan HumanEval menggunakan masing-masing 100 sampel acak per benchmark. Ukuran sampel ini cukup untuk indikasi awal, namun masih menyisakan ruang variansi statistik 5–10% poin per metrik. Studi lanjutan disarankan menggunakan minimal 500 sampel per benchmark atau melaporkan interval kepercayaan secara eksplisit.
3. **Keterbatasan Instrumen Evaluasi pada Reasoning Model (Qwen 3.5).** Sebagaimana dijabarkan pada Sub-bab 4.3.3, skor akurasi Qwen 3.5 pada benchmark GSM8K terdampak oleh interaksi antara format keluaran chain-of-thought (`<think> ... </think>`), anggaran token yang terbatas, dan logika parser berlapis. Skor GSM8K Qwen 3.5 pada Tabel 4.5 oleh karenanya dilaporkan sebagai lower bound dan tidak dapat secara langsung dibandingkan dengan skor LFM 2.5 (yang non-reasoning) tanpa konteks ini.
4. **Pengukuran Termal dan Konsumsi Energi.** Penelitian belum menyertakan pengukuran suhu CPU secara periodik (`/sys/class/thermal/thermal_zone`) maupun konsumsi baterai per 1.000 token yang diproduksi. Keduanya merupakan metrik krusial untuk evaluasi praktis dalam konteks Mobile Edge AI yang sangat sensitif terhadap thermal throttling dan ketahanan baterai, sehingga direkomendasikan untuk dieksplorasi

pada penelitian lanjutan.

5.3 Saran

Berdasarkan batasan dan temuan penelitian, penulis merekomendasikan beberapa pengembangan untuk penelitian selanjutnya di bidang Edge Intelligence:

1. **Eksplorasi Akselerator Komputasi Heterogen.** Penelitian selanjutnya disarankan mengintegrasikan kerangka inferensi yang mendukung delegasi beban kalkulasi pada modul AI khusus, seperti Neural Processing Unit (NPU) atau akselerasi GPU mobile via Vulkan/OpenCL, untuk menembus limitasi komputasi yang bersifat CPU-bound.
2. **Evaluasi Algoritma Kuantisasi Berbasis Aktivasi.** Guna mempertahankan kualitas kognitif pada tingkat kompresi rendah, disarankan melakukan komparasi metode k-quants dengan algoritma mutakhir seperti AWQ (Lin dkk., 2023) yang lebih adaptif dalam melindungi bobot outliers.
3. **Integrasi Antarmuka Pengguna Grafis (Native GUI).** Untuk meningkatkan utilitas bagi pengguna akhir, disarankan mengembangkan purwarupa terminal ini ke dalam bentuk aplikasi Android native menggunakan Java Native Interface (JNI). Tujuannya adalah mentransformasi sistem berbasis CLI menjadi asisten AI interaktif yang lebih intuitif dan aksesibel.

DAFTAR PUSTAKA

- Ahmad, S., & Safudin, T. (2024). Pengembangan Chatbot AI Large Language Model (LLM) untuk Layanan Informasi dan Konsultasi RS Brawijaya. *Jurnal Sistem Informasi dan Teknologi*, 6(3), 121-134.
- Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. *Advances in Neural Information Processing Systems (NeurIPS)* 36, 10088-10115.
- Frantar, E., Ashkboos, S., Hoefler, T., & Alistarh, D. (2023). GPTQ: Accurate Post-Training Quantization for Generative Pre-Trained Transformers. *International Conference on Learning Representations (ICLR)*.
- Gong, R., Yong, Y., Gu, S., Huang, Y., Lv, C., Zhang, Y., Liu, X., & Tao, D. (2024). What Makes Quantization for Large Language Models Hard? An Empirical Study from the Lens of Perturbation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(15), 18082-18089.
- Jin, R., Du, J., Huang, W., Liu, W., Luan, J., Wang, B., & Xiong, D. (2024). A Comprehensive Evaluation of Quantization Strategies for Large Language Models. *Findings of the Association for Computational Linguistics: ACL 2024*, 12186-12215.
- Lin, J., Tang, J., Tang, H., Yang, S., Dang, X., Gan, C., & Han, S. (2023). AWQ: Activation-Aware Weight Quantization for On-Device LLM Compression and Acceleration. *Proceedings of Machine Learning and Systems (MLSys)* 6.
- Nurohim, A., Saifulloh, M., & Rahmawati, D. (2025). Analisis Komparatif Large Language Models DeepSeek dan Qwen dalam Klasifikasi Sentimen Berbahasa Indonesia. *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, 12(2), 235-246.
- Ray, P., & Pradhan, T. (2026). Performance Analysis of Localised Large Language Models in Resource-Constrained Edge for Python and Rust APIs. *Internet of Things*, 31, 101324.
- Sevim, B., & Ibrahim, M. (2024). Large Language Models (LLMs) Assisted

Wireless Network Deployment in Urban Settings. IEEE Vehicular Technology Conference (VTC2024-Fall), 1-6.

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). LLaMA: Open and Efficient Foundation Language Models. arXiv preprint arXiv:2302.13971.

Zhan, H., Wei, S., He, Y., Liu, M., Gao, Y., Ma, Y., Yu, J., Wang, B., Yu, X., Zhang, S., & Wang, X. (2025). Quantized Large Language Models in Biomedical NLP: Evaluation and Recommendations. npj Digital Medicine, 8(1), 1-12.

Zhang, X., Nie, J., Huang, Y., Xie, G., Xiong, Z., Liu, J., Niyato, D., & Shen, X. (2024). Edge Intelligence Optimization for Large Language Model Inference with Batching and Quantization. IEEE Wireless Communications, 31(4), 12-18.